

Система машинного перевода с контекстным пониманием

1. Цель системы

Система предназначена для автоматического перевода текстов на различные языки с учетом контекста, культурных особенностей и языковых нюансов, обеспечивая высокую точность и естественность перевода. Система анализирует текст целиком, учитывает семантические связи и предоставляет перевод, максимально соответствующий исходному смыслу.

2. Пользователи системы

1. *Переводчик* — использует систему для получения чернового перевода, корректирует и уточняет результаты, добавляет специфические термины или стилистические особенности.
2. *Редактор контента* — применяет систему для локализации текстов (например, сайтов, документации, маркетинговых материалов) с учетом культурных и языковых особенностей целевой аудитории.
3. *Администратор системы* — формирует отчеты о точности переводов, анализирует статистику использования системы и обновляет обучающие данные для повышения качества.

3. Структура системы и её подсистемы

1. *Подсистема ввода и парсинга текста* — принимает входной текст, определяет его язык, структуру и контекст (например, стиль, тематику, целевую аудиторию).
2. *Подсистема хранения и обработки данных* — хранит словари, корпусы текстов, модели машинного обучения и обрабатывает входные данные для последующего анализа.
3. *Подсистема анализа и контекстного моделирования* — анализирует семантические связи, контекст и культурные особенности текста, используя модели машинного обучения для выбора оптимальных переводческих решений.
4. *Подсистема генерации перевода* — создает перевод текста на целевой язык, учитывая результаты контекстного анализа, и формирует рекомендации по улучшению перевода.

5. *Интерфейсная подсистема* — предоставляет визуализацию перевода, инструменты для ручной корректировки, а также отображение альтернативных вариантов перевода и отчетов о качестве.

4. Связи и взаимодействия между подсистемами

1. Входной текст поступает в подсистему ввода и парсинга, где определяется его структура и контекст.
2. Обработанные данные передаются в подсистему хранения и обработки для структурирования и подготовки к анализу.
3. Подсистема анализа и контекстного моделирования использует обработанные данные для создания семантической модели текста.
4. Рекомендации анализа направляются в подсистему генерации перевода, которая формирует финальный перевод.
5. Перевод и рекомендации выводятся через интерфейсную подсистему, где пользователи могут вносить корректировки, которые учитываются в следующем цикле обработки.

5. Основные сценарии работы пользователей с системой

1. Сценарий чернового перевода. Переводчик загружает текст, система предоставляет автоматический перевод с учетом контекста, переводчик корректирует результат и сохраняет финальную версию.
2. Сценарий локализации контента. Редактор контента вводит текст и параметры локализации (например, целевой рынок, стиль), система предлагает перевод с учетом культурных особенностей, редактор подтверждает или вносит изменения.
3. Сценарий анализа качества перевода. Администратор формирует отчеты о точности переводов, анализирует статистику использования системы и обновляет обучающие данные для повышения качества..

6. Три направления развития системы

1. Разработка модели для разрешения лексической многозначности. Внедрение нейросетевой модели для автоматического выбора единственно верного перевода многозначных слов на основе

микро- и макроконтекста (предложение, абзац, документ) с целью повышения точности перевода сложных идиом и фраз.

2. Создание модуля обучения в реальном времени на основе обратной связи. Разработка механизма, который мгновенно применяет пользовательские корректировки (исправления переводчика и редактора) для дообучения соответствующей контекстной или генеративной модели без задержки в рамках текущей сессии, обеспечивая оперативное повышение качества для специфических терминов и стилистических особенностей.
3. Интеграция модуля перевода для двух целевых региональных диалектов. Добавление двух конкретных региональных вариаций языка с разработкой отдельных лингвистических профилей, учитывающих грамматические, лексические и культурные различия, для повышения точности локализации контента на двух целевых рынках.