

Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет информационных технологий и управления

Кафедра интеллектуальных информационных технологий

ОТЧЕТ

по лабораторной работе №1

по дисциплине «Естественно-языковой интерфейс интеллектуальных систем»

Студенты гр. 321701

В. В. Германенко

К. В. Романов

Руководитель

Б. Ю. Крапивин

Минск 2026

Содержание

1	ХОД ВЫПОЛНЕНИЯ ЛАБОРАТОРНОЙ РАБОТЫ	3
1.1	Структуры хранения данных	3
1.1.1	Реляционная база данных (SQLite)	3
1.1.2	Внутренние структуры для морфологии и синтеза . .	4
1.1.3	Структуры для извлечения лексем и словосочетаний .	4
1.2	Алгоритмы обработки данных	5
1.2.1	Загрузка и предобработка текста	5
1.2.2	Извлечение слов и словосочетаний	5
1.2.3	Формирование морфологического словаря	5
1.2.4	Синтез новых словосочетаний	6
1.3	Структурно-функциональные схемы программы	6
1.4	Оценка быстродействия программы	8
	Заключение	10

1 ХОД ВЫПОЛНЕНИЯ ЛАБОРАТОРНОЙ РАБОТЫ

Тема: Программирование операций логического вывода прикладных и неклассических логик.

Цель: Приобрести навыки разработки и программирования прикладных систем логического вывода, включая системы неклассического логического вывода.

Задание:

Требуется спроектировать и программно реализовать структуры хранения данных, алгоритмы их обработки, необходимые в рамках следующих базовых требований к разрабатываемому приложению:

- входные данные – текст заданного естественного языка;
- выходные данные – перечень лексем с дополнительной информацией согласно задания;
- взаимодействие с пользователем посредством графического интерфейса (интерфейс должен быть интуитивно-понятным и дружелюбным пользователю);
- наличие системы средств помощи пользователю;
- обеспечение возможности построения, сохранения, просмотра, редактирования, пополнения, фильтрации и поиска по заданному условию, документирования автоматически получаемого словаря либо заданной его части;
- поддержка различных форматов представления входных данных (TXT, RTF, PDF, DOC, DOCX).

Программа должна выводить список слов, упорядоченный по алфавиту и включающий только лексемы с дополнительно оформленными записями для образования словосочетаний. В этих записях должны храниться слова (точнее, ссылки на эти слова), с которыми данное слово может сочетаться. При этом возможно обеспечение автоматизированного извлечения из исходных текстов типовых словосочетаний с их последующей обработкой. *Можно добавить средства синтеза словосочетаний, но при этом в словарь необходимо будет добавить правила формирования словоформ (см. задание 2).

1.1 Структуры хранения данных

1.1.1 Реляционная база данных (SQLite)

Основное хранилище реализовано в виде реляционной базы данных SQLite с использованием SQLAlchemy ORM. Схема включает три основные таблицы:

- Таблица **words** содержит записи о словах с полями: уникальный идентификатор, лемма (основная форма), часть речи. Каждая запись связана со словосочетаниями через таблицу связей.

- Таблица **collocations** хранит словосочетания с полями: идентификатор, текст словосочетания в лемматизированной форме, частота встречаемости в корпусе, фрагмент исходного текста для контекста.

- Таблица связи **word_collocation** устанавливает связи «многие-ко-многим» между словами и словосочетаниями, гарантируя отсутствие дубликатов через составной первичный ключ.

Сервисный класс **DictionaryDB** инкапсулирует операции с базой данных: добавление и поиск слов и словосочетаний, получение алфавитных списков, реализацию поиска по подстроке и других операций, требуемых техническим заданием.

1.1.2 Внутренние структуры для морфологии и синтеза

Для обработки морфологии и синтеза словосочетаний в оперативной памяти поддерживаются следующие структуры:

Класс **MorphoEntry** описывает лексему с её словоформами: основа (лемма), часть речи и словарь форм, генерируемых по правилам (множественное число для существительных, временные формы для глаголов, степени сравнения для прилагательных). Каждая форма доступна через соответствующий метод.

Класс **MorphoDictionary** представляет словарь в памяти с индексами по леммам и частям речи, обеспечивая быстрый доступ для операций синтеза. Он загружается либо из обработанного текста, либо из базы данных.

Класс **RandomSynthesizer** реализует синтез новых словосочетаний на основе морфологического словаря. Алгоритм использует матрицу совместимости частей речи (например, «прилагательное + существительное», «глагол + наречие») и применяет правила согласования словоформ для генерации грамматически корректных сочетаний.

1.1.3 Структуры для извлечения лексем и словосочетаний

Класс **TextProcessor** на основе библиотеки **sraCy** реализует извлечение лингвистической информации из текста. Метод **extract_words** выделяет леммы и части речи, фильтруя стоп-слова и пунктуацию. Метод **extract_collocations** анализирует синтаксические зависимости между токенами (отношения **amod**, **compound**, **dobj** и другие) для выявления типичных словосочетаний, которые затем лемматизируются и подсчитываются.

1.2 Алгоритмы обработки данных

1.2.1 Загрузка и предобработка текста

- а) Пользователь загружает текстовый файл в одном из поддерживаемых форматов (TXT, RTF, PDF, DOC, DOCX).
- б) Программа на основании расширения файла выбирает соответствующий парсер.
- в) Извлечение текста из файла.
- г) Производится сбор статистики по количеству слов и словосочетаний.
- д) Отображение результатов в интерфейсе.

1.2.2 Извлечение слов и словосочетаний

- а) Запуск потока обработки текста для обеспечения отзывчивости интерфейса.
- б) Извлечение лемм и определение частей речи.
- в) Добавление в базу данных записей о словах.
- г) Анализ синтаксических зависимостей для выявления словосочетаний.
- д) Группировка найденных словосочетаний.
- е) Вычисление частоты появления словосочетания в тексте.
- ж) Сохранение в базу данных со связями на составляющие слова.

1.2.3 Формирование морфологического словаря

- а) Выбор источника данных для формирования словаря:
 - 1) Вариант: загрузка из исходного текста проекта.
 - Переход к алгоритму «Загрузка и предобработка текста».
 - Создание объектов словаря:
 - Извлечение лемм и их частей речи.
 - Образование новых словоформ с помощью простых правил.
 - 2) Вариант: загрузка существующего словаря из файла (TXT, CSV).
 - Выбор файла словаря пользователем.
 - Определение расширения файла и выбор соответствующего парсера.
 - Парсинг текста файла.
 - Создание объектов словаря:
 - Извлечение лемм и их частей речи.
 - Образование новых словоформ с помощью простых правил.
 - Заполнение базы данных.

– Активация словаря в системе.

1.2.4 Синтез новых словосочетаний

- а) Проверка морфологического словаря на пустоту. Если словарь пуст, алгоритм завершается.
- б) Инициализация счетчика попыток генерации (максимум 20 итераций).
- в) В цикле выполняются следующие действия:
 - 1) Выбор случайной пары слов из словаря.
 - 2) Проверка совместимости частей речи по матрице совместимости.
 - 3) При успешном совпадении:
 - Генерация словосочетания с правильно согласованными словоформами.
 - Добавление результата в список синтезированных фраз.
 - 4) Увеличение счетчика попыток.
- г) Вывод или сохранение полученных словосочетаний.

1.3 Структурно-функциональную схемы программы




Рисунок 1.1 – Морфологический словарь




Рисунок 1.2 – Обработка текста




Рисунок 1.3 – Получение исходного текста




Рисунок 1.4 – Просмотр словаря и коллокаций




Рисунок 1.5 – Синтез нового словосочетания

1.4 Оценка быстродействия программы

Спецификация устройства, на котором производились замеры:

- а) RAM: 16 GB
- б) CPU: Ryzen 5 5500u
- в) GPU: Radeon Vega 7
- г) OS: Ubuntu 22.04.5 LTS

– Тест обработки текста:

Короткий (100 слов):

Извлечение слов: 0.021 сек (60 слов)

Извлечение словосочетаний: 0.016 сек (5 сочетаний)

- Общее время: 0.038 сек
Средний (1000 слов):
Извлечение слов: 0.147 сек (600 слов)
Извлечение словосочетаний: 0.152 сек (5 сочетаний)
Общее время: 0.299 сек
Длинный (5000 слов):
Извлечение слов: 0.755 сек (3000 слов)
Извлечение словосочетаний: 0.730 сек (5 сочетаний)
Общее время: 1.485 сек
- Тест поиска по словарю:
Всего слов в словаре: 113
Поиск 'a': 0.0086 сек, найдено: 42
Поиск 'ab': 0.0037 сек, найдено: 1
Поиск 'abc': 0.0018 сек, найдено: 0
Поиск 'test': 0.0016 сек, найдено: 0
Поиск 'nonexistent': 0.0016 сек, найдено: 0
 - Тест фильтрации по словарю:
Всего слов в словаре: 113
Фильтрация по части речи:
NOUN: 0.0000 сек (54 слов)
VERB: 0.0000 сек (23 слов)
ADJ: 0.0000 сек (36 слов)
ADV: 0.0000 сек (0 слов)
PROPN: 0.0000 сек (0 слов)
Текстовая фильтрация (startswith):
'a*': 0.0001 сек (5 слов)
'ab*': 0.0000 сек (0 слов)
'abc*': 0.0000 сек (0 слов)
'b*': 0.0000 сек (6 слов)
'c*': 0.0000 сек (15 слов)
'th*': 0.0001 сек (1 слов)
'the*': 0.0000 сек (0 слов)

Заключение

В рамках лабораторной работы был разработан система по автоматизированной обработке текста на английском языке с извлечением словосочетаний и простым генератором словосочетаний на основе слов из текста.