

Министерство образования Республики Беларусь
Учреждение образования
Белорусский государственный университет информатики и
радиоэлектроники

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

ОТЧЁТ
по курсу
«Естественно-языковой интерфейс интеллектуальных систем»

Лабораторная работа №2
«Построение и использование корпусов текстов естественного языка.»

Выполнили студенты гр. 321701:

Политыко И.А.
Лукашов В.А.

Проверил:

Крапивин Ю.Б.

Минск 2026

Цель работы

1. Изучить принципы построения корпусов текстов, виды разметки и способы аннотирования, инструменты работы с корпусами текстов.
2. Построить корпус текстов и разработать корпусный менеджер.

Задачи лабораторной работы

1. Сформировать электронный корпус текстов по выбранной предметной области.
2. Используя результаты лабораторной работы №1 (возможность получения лингвистических сведений для произвольной леммы естественного языка) разработать корпусный менеджер, обеспечивающий базовую функциональность работы с созданным корпусом текстов.

Задание

Вариант 2: Требуется спроектировать и программно реализовать структуры хранения данных, алгоритмы их обработки, необходимые в рамках следующих базовых требований к разрабатываемому приложению:

- входные данные – фрагмент текста (фраза или слово) на естественном языке – запрос корпусному менеджеру;
- выходные данные – частотные характеристики словоформ, лексем, грамматических категорий, леммы, морфологические характеристики словоформ и их метаданные (библиографические, типологические), конкордансные списки, согласно согласованным с преподавателем требованиям к функциональности корпусного менеджера;
- взаимодействие с пользователем посредством графического интерфейса (интерфейс должен быть интуитивно-понятным и дружелюбным пользователю);
- наличие системы средств помощи пользователю;

Поддерживаемые форматы входных данных: TXT, RTF

Язык текста: Русский

Предметная область: Кулинария

Используемые библиотеки

1. FastAPI — библиотека Python для создания функций обработки запросов. Из-за своей высокой производительности FastAPI идеально подходит для создания современных веб-приложений и API.

2. Pydantic — библиотека Python для создания удобных моделей для представления сущностей внутри программы. Модели Pydantic автоматически проверяют типы данных поступающей информации, что значительно упрощает валидацию данных и обработку ошибок.

3. pymorphy3 — библиотека Python для морфологического анализа русского языка. Используется для лемматизации, определения части речи, падежа, числа, рода и других морфологических характеристик.

4. razdel — библиотека Python для токенизации русского текста. Используется для разделения текста на отдельные слова (токены).

5. striprtf — библиотека Python для чтения и обработки RTF-файлов. Используется для извлечения текста из документов формата RTF.

Интерфейс

Интерфейс приложения включает следующие элементы:

- **Окно управления корпусом:** пользователь загружает, удаляет, смотрит, редактирует тексты корпуса заданные TXT или RTF-файлами.
- **Окно статистики:** пользователь может видеть статистику по корпусу: количество слов, уникальных словоформ, лемм и т.д.
- **Окно поиска:** позволяет найти слово или набор символов, а также конкордатный список.
- **Панель помощи:** содержит документацию с используемыми терминами и возможностями системы.




Рисунок 1: Интерфейс управления корпусом




Рисунок 2: Интерфейс статистики




Рисунок 3: Интерфейс поиска




Рисунок 4: Интерфейс панели помощи

Структура хранения данных

Данные хранятся в базе данных в директории backend/data.

В коллекции документов хранятся:

- уникальный идентификатор (имя файла);
- заголовок рецепта;
- текст рецепта (ингредиенты и приготовление);
- объект метаданных, где каждое поле содержит:
 - источник файла;
 - информация об авторстве и классификации:
 - автор, дата, жанр — пустые значения;
 - тип текста — кулинарный текст;
- статистика текста:
 - количество слов;
 - количество символов;
 - дата создания — временная метка ISO;
- общее количество документов и слов в коллекции.

Структурная схема приложения




Рисунок 3: Структурная схема приложения

Описание алгоритмов

Алгоритм работы программы

1. Начало.
2. Пользователь выбирает TXT-, DOC-, DOCX-, PDF-, RTF-файл через интерфейс.
3. Проверяется существование файла и его формат.
4. Извлекается текст из файла с помощью TxtParser, DocParser, DocxParser, PdfParser, RtfParser.
5. Текст токенизируется с помощью библиотеки razdel.
6. Токены формируются в объект(текст).
7. Объект сохраняется в db-файл словаря.
8. Результаты отображаются в интерфейсе.

9. Пользователь может выполнять операции:
 - 1) Удаление/изменение/просмотр текста;
 - 2) Поиск по набору символов;
 - 3) Получение статистики;
 - 4) Получение справки;
 - 5) Получение конкорданса;
10. Конец.

Алгоритм поиска строчки по набору символов

1. Начало.
2. Пользователь вводит набор символов.
3. Система ищет набор символов в словаре и ближайшие символы к нему.
4. Если набор символов найден, система возвращает строки с найденными символами, и их количество.
5. Если набор символов не найден, возвращается ошибка.
6. Конец.

Тест производительности

Для оценки производительности приложения был проведён тест на конкорданс в корпусе объёмом **778** слов. Среднее время обработки составило ~8 миллисекунд на ПК HP Victus Pavilion 15, процессор: AMD Ryzen 5 8645HS, объём оперативной памяти: 16 ГБ.

Результаты замеров:

Количество слов	Время обработки (мс)	мс/токе н
299	4	0.013
573	7	0.012
778	8	0.010

Основное время затрачивается на поиск.

Вывод

Разработанное приложение строит и использует корпус текстов естественного языка, извлечённых из TXT-, DOC-, DOCX-, PDF-, RTF-файлов. Сформирован электронный корпус текстов по предметной области кулинария с базовой функциональностью работы с созданным корпусом текстов. Перспективами использования приложения можно назвать расширение функционала для поддержки английского языка, а также добавить поддержку новых форматов файлов.

