

Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

ОТЧЕТ
по лабораторной работе
по дисциплине «Естественно языковой интерфейс в интеллектуальных
системах»
на тему:

Автоматическое распознавание языка текста

Студенты гр. 321701

И. А. Политыко

В. А. Лукашов

Руководитель

Ю. Б. Крапивин

Минск 2026

Содержание

Перечень условных обозначений	3
1 Алгоритмы распознавания языка	4
2 Разработка системы распознавания языка	6
Заключение	13
Список использованных источников	14

Перечень условных обозначений

ПОЯ	—	Поисковый образ языка
ПОД	—	Поисковый образ документа
ЕЯ	—	Естественный язык
ОоР	—	Расстояние Out-of-Place между ранжированными профилями
MLP	—	Многослойный перцептрон
N-грамма	—	Подстрока длины N
Ассигасу	—	Доля верно классифицированных текстов
F-мера	—	Гармоническое среднее точности и полноты
PDF	—	Переносимый формат документов
API	—	Программный интерфейс приложения
REST	—	Архитектурный стиль взаимодействия компонентов
JSON	—	Текстовый формат обмена данными
SQL	—	Язык структурированных запросов
СУБД	—	Система управления базами данных
ЛВС	—	Локальная вычислительная сеть
SPA	—	Одностраничное веб-приложение

1 Алгоритмы распознавания языка

По варианту 13 нужно понять, на каких языках написан PDF: на русском, на немецком или на обоих сразу. Для этого сравниваются три способа — короткие слова, частотные слова и нейросеть.

Сначала по учебным текстам для каждого языка собирается поисковый образ языка (ПОЯ): какие слова или куски текста для него обычны. У нового документа по тем же правилам строится поисковый образ документа (ПОД). Дальше для каждого языка считается оценка принадлежности. Для слов это произведение вероятностей, для нейросети — доля кириллических и латинских N-грамм. Язык считается найденным, если его доля не меньше 0,15. Поэтому смешанный документ показывает оба языка, а не только тот, которого чуть больше. Дополнительно считается расстояние OoP (Out-of-Place): насколько по-разному выстроены списки частых элементов.

Учебные тексты лежат в каталоге `corpus/train`: по семь медицинских заметок на каждый язык, примерно 50 Кбайт русского текста и 85 Кбайт немецкого. Для проверки отдельно приготовлены шестнадцать текстов: обычные фразы, длинные слова из частотного списка, редкие длинные слова и смешанные русско-немецкие фрагменты. В обучение они не входят.

Перед сравнением текст приводится к нижнему регистру, буква «ё» заменяется на «е». Немецкие умлауты сохраняются. Русские слова приводятся к начальной форме, немецкие только к нижнему регистру. Короткие служебные слова вроде «и» или «der» не выбрасываются: по ним языки хорошо отличаются.

В методе коротких слов в образ языка попадают слова не длиннее пяти букв, если в учебных текстах они встретились больше трёх раз. Чем слово чаще, тем выше его вероятность. Если слова в образе нет, ему даётся очень маленькая вероятность, чтобы расчёт не обрывался. Документ оценивается как произведение вероятностей его коротких слов:

$$P(\text{lang} \mid \text{doc}) = \prod_{l \in L_{\text{short}}} P(l \mid \text{lang}). \quad (1.1)$$

Если коротких слов в тексте нет, метод язык не назначает. Иначе берутся все языки, чья доля после softmax не ниже порога. Считают сумму логарифмов: само произведение на длинном тексте слишком быстро становится нулём.

В методе частотных слов в образ входят пятьдесят самых обычных слов, длина здесь не важна. С документом сравниваются только слова из этого короткого списка. Формула та же, что и (1.1). Если ни одно слово документа не входит в список, метод тоже ничего не обнаруживает.

Нейросеть смотрит не на целые слова, а на короткие куски текста длиной от одного до пяти символов: такой кусок в тексте есть или нет. По доли кириллицы и латиницы она показывает оба языка, если оба алфавита встречаются в документе. Расстояние ОоР для неё не считается.

ОоР сравнивает два списка, упорядоченных от частых элементов к редким. Для каждого элемента смотрят, насколько разъехались его места в списках. Если элемента во втором списке нет, разница берётся большой:

$$d(A, B) = \sum_{g \in A \cup B} |\text{pos}_A(g) - \text{pos}_B(g)|. \quad (1.2)$$

Число растёт вместе с длиной списков, поэтому у коротких слов и у пятидесяти частых слов оно разного масштаба. Решение словесные методы принимают по вероятности (1.1), а не по минимуму ОоР.

2 Разработка системы распознавания языка

Система запускается через Docker Compose. Внутри три части: база PostgreSQL, сервер на Python и страница в браузере. Загружать можно только PDF.

Как части связаны, показано на рисунке 2.1. Сервер принимает файл, достаёт из него текст, прогоняет три метода и сохраняет результат. На странице видны все найденные языки, их доли и время.




Рисунок 2.1 – Структура системы распознавания языка.

При первом запуске сервер сам читает учебные тексты, строит образы языков и обучает сеть. Проверочные тексты тоже появляются в списке документов. Эта последовательность показана на рисунке 2.2.




Рисунок 2.2 – Обучение моделей при запуске сервера.

Обычная проверка проще: пользователь выбирает PDF, сервер распознаёт язык и возвращает ответ каждого метода. Это показано на рисунке 2.3.




Рисунок 2.3 – Распознавание загруженного PDF.

Учебные тексты в списке документов не показываются. Там лежат проверочные фразы и файлы, которые загрузил пользователь. Назначение таблиц собрано в таблице 2.1, схема — на рисунке 2.4.

Таблица	Назначение
documents	Заголовок, текст, язык, результат
training_texts	Учебные тексты
language_profiles	Слова и частоты образов языков
recognition_results	Ответ каждого метода
eval_queries	Проверочные фразы
eval_runs	Сводка прогона оценки

Таблица 2.1 – Таблицы базы данных.




Рисунок 2.4 – Схема базы данных.

В браузере четыре страницы: распознавание, список документов, оценка качества и справка. После запуска интерфейс открывается по адресу <http://localhost:8080>. Список документов можно сохранить и распечатать. Внешний вид страниц показан на рисунках 2.5–2.7.




Рисунок 2.5 – Страница распознавания смешанного PDF.




Рисунок 2.6 – Список документов с найденными языками.




Рисунок 2.7 – Страница оценки качества методов.

Качество проверялось на шестнадцати текстах: обычные русские и немецкие фразы, длинные слова из частотного списка, редкие длинные слова и смешанные фрагменты. Ассигасу здесь — доля текстов, у которых набор найденных языков в точности совпал с эталоном. Точность и полнота считаются по языкам внутри каждого текста и усредняются. Цифры собраны в таблице 2.2.

Метод	Асс	P	R	F1	мс
Коротких слов	0,625	0,688	0,656	0,672	1,39
Частотных слов	0,875	0,875	0,875	0,875	1,44
Нейросетевой	1,000	1,000	1,000	1,000	23,10

Таблица 2.2 – Результаты на шестнадцати проверочных текстах.

Метод коротких слов не срабатывает на тексте без лексем короче шести букв. Метод частотных слов не видит редкие слова вне топ-50. Нейросеть по алфавиту находит оба языка даже в смешанном документе. На длинном документе по времени методы тоже различаются. Частотные слова заканчивают быстрее: им хватает короткого списка. Сравнение показано на рисунках 2.8 и 2.9.




Рисунок 2.8 – Сравнение методов по качеству.




Рисунок 2.9 – Среднее время на проверочных текстах.

Для ручной проверки рядом с программой лежат PDF: русские, немецкие и смешанный `de_ru_text.pdf`. Их можно загрузить на странице распознавания.

Заключение

Сделана система, которая по PDF показывает все языки варианта, которые есть в тексте: русский, немецкий или оба. Используются короткие слова, частотные слова и нейросеть. Всё запускается локально через Docker Compose.

На шестнадцати проверочных текстах методы уже различаются по качеству: короткие слова дают F1 0,672, частотные — 0,875, нейросеть — 1,000. На длинном документе заметно быстрее метод частотных слов: ему не нужно просматривать весь текст.

Список использованных источников

- [1] Cavnar W., Trenkle J. N-Gram-Based Text Categorization // Proceedings of SDAIR-94. — 1994. — Режим доступа: <https://www.let.rug.nl/vannoord/TextCat/textcat.pdf>. — Дата доступа: 23.09.2026.
- [2] Pedregosa F. и др. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830.
- [3] FastAPI documentation [Электронный ресурс]. — Режим доступа: <https://fastapi.tiangolo.com/>. — Дата доступа: 23.09.2026.
- [4] Korobov M. Morphological Analyzer and Generator for Russian and Ukrainian Languages // Analysis of Images, Social Networks and Texts. — 2015. — P. 320–332.
- [5] rypdf [Электронный ресурс]. — Режим доступа: <https://rypdf.readthedocs.io/>. — Дата доступа: 23.09.2026.
- [6] PostgreSQL 16 Documentation [Электронный ресурс]. — Режим доступа: <https://www.postgresql.org/docs/16/>. — Дата доступа: 23.09.2026.
- [7] React documentation [Электронный ресурс]. — Режим доступа: <https://react.dev/>. — Дата доступа: 23.09.2026.
- [8] MLPClassifier [Электронный ресурс]. — Режим доступа: https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html. — Дата доступа: 23.09.2026.