

Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

ОТЧЕТ
по лабораторной работе
по дисциплине «Естественно языковой интерфейс в интеллектуальных
системах»
на тему:

Автоматическое реферирование документов

Студенты гр. 321701

И. А. Политыко

В. А. Лукашов

Руководитель

Ю. Б. Крапивин

Минск 2026

Содержание

Перечень условных обозначений	3
1 Алгоритм построения реферата	4
2 Разработка и исследование системы	6
Заключение	13

Перечень условных обозначений

TF	— Частота термина в документе или предложении
IDF	— Обратная документная частота
TF-IDF	— Вес термина по частоте и редкости в коллекции
Posd	— Функция положения предложения в документе
Posp	— Функция положения предложения в абзаце
Score	— Суммарный вес слов предложения
OSTIS	— Open Semantic Technology for Intelligent Systems
F-мера	— Гармоническое среднее точности и полноты
PDF	— Переносимый формат документов
API	— Программный интерфейс приложения
REST	— Архитектурный стиль взаимодействия компонен- тов
JSON	— Текстовый формат обмена данными
SQL	— Язык структурированных запросов
СУБД	— Система управления базами данных
SPA	— Одностраничное веб-приложение

1 Алгоритм построения реферата

По варианту 22 обрабатываются русский и немецкий тексты двух областей: научные материалы по медицине и критика предметов изобразительного искусства. Методика — sentence extraction и семантическая сеть OSTIS.

Сначала из файла извлекается текст. Первая непустая строка считается заголовком. Язык определяется по доле кириллицы. Дальше документ режется на абзацы по пустой строке и на предложения по точке, вопросу и восклицанию.

В вес не входят числа, стоп-слова и слова чужого алфавита: латиница в русском тексте, кириллица в немецком. Русские словоформы приводятся к нормальной форме словарём `rumorphy3`, немецкие — стеммером `Snowball`. Так выполняется требование методички не учитывать латинские вставки, цифры и служебную лексику.

Базовый вес слова считается по модифицированной TF-IDF:

$$w(t, D) = 0,5 \left(1 + \frac{\text{tf}(t, D)}{\text{tf}_{\max}(D)} \right) \log \frac{|DB|}{\text{df}(t)}. \quad (1.1)$$

Вес предложения — произведение трёх функций:

$$\text{Posd}(S_i) = 1 - \frac{BD(S_i)}{|D|}, \quad \text{Posp}(S_i) = 1 - \frac{BP(S_i)}{|P|}, \quad (1.2)$$

$$\text{Score}(S_i) = \sum_{t \in S_i} \text{tf}(t, S_i) w(t, D), \quad (1.3)$$

$$W(S_i) = \text{Posd}(S_i) \cdot \text{Posp}(S_i) \cdot \text{Score}(S_i). \quad (1.4)$$

Здесь $|D|$ — число символов документа, $BD(S_i)$ — символы до предложения в документе, $|P|$ — длина абзаца, $BP(S_i)$ — символы до предложения в абзаце. В реферат попадают десять предложений с наибольшим W , но в том порядке, в каком они стоят в тексте.

Позиционные множители поднимают начало документа и начало абзаца. Поэтому метод не сводится к «взять первые десять»: позднее предложение с редкими терминами может обойти раннее бытовое. Для сравнения рядом считается базовый реферат — ровно первые десять предложений без весов.

Реферат ключевых слов строится как дерево. Опорные вершины — восемь лексем с наибольшим $\text{tf} \cdot \text{IDF}$. Если пара соседних лексем встретилась не меньше двух раз и одно из слов уже в дереве, словосочетание вешается ребёнком. Это повторяет пример методички: «лазер / синий лазер».

Часть OSTIS — семантическая сеть: узлы-понятия и дуги-отношения. Документ относится к предметной области и связан с ключевыми понятиями. Понятие включает словосочетание, принадлежит области и встречается с другим понятием, если оба оказались в одном предложении.

Точность и полнота считаются по множеству номеров предложений. Эталон размечен вручную: в него входят тезисы о тяжести, схеме лечения, деэскалации либо о композиции, смещении и отказе сводить работу к лозунгу. Бытовые описания кашля или «просто чёрного пятна» в эталон не входят.

2 Разработка и исследование системы

Система собрана из трёх контейнеров Docker Compose: React-интерфейс за nginx, FastAPI и PostgreSQL 16. Порты 8082 и 8002, чтобы не пересекались со второй лабораторной. Схема уровней — на рисунке 2.1.




Рисунок 2.1 – Архитектура системы реферирования.

На сервере модули разделены по полям. `document_loader` читает TXT и PDF. `text_processing` токенизирует и лемматизирует. `summarizer` считает Posd, Posp, Score, дерево ключей и тройки сети. `indexer` хранит коллекцию и пересчитывает документные частоты при каждой загрузке или удалении: IDF зависит от всей базы. `evaluator` сравнивает выбранные предложения с эталоном и рисует графики.

Сценарий загрузки показан на рисунке 2.2. Пользователь указывает предметную область варианта, получает активную ссылку на документ и два раздела реферата. Сценарий оценки — на рисунке 2.3.




Рисунок 2.2 – Построение реферата после загрузки файла.




Рисунок 2.3 – Расчёт точности и выгрузка графиков.

Вход и выход лежат в трёх таблицах, рисунок 2.4. В `documents` хранятся текст, классический реферат, базовый реферат, дерево ключей, сеть и разбор каждого предложения. `doc_terms` держит частоты слов документа, `global_terms` — документную частоту для IDF.




Рисунок 2.4 – Схема базы данных.

Интерфейс открывается по адресу <http://localhost:8082>. На карточке документа есть ссылка на исходный текст, сохранение в файл и печать. Предложения реферата подсвечены в источнике. Сеть рисуется графом, отношения подписаны. Внешний вид — на рисунках 2.5–2.8.




Рисунок 2.5 – Страница загрузки документа.




Рисунок 2.6 – Классический реферат и подсветка в исходном тексте.




Рисунок 2.7 – Семантическая сеть и дерево ключевых слов.




Рисунок 2.8 – Сравнение sentence extraction с базовым методом.

Тестовая коллекция — четыре авторских текста близкой длины: внебольничная пневмония и разбор «Чёрного квадрата», каждый по-русски и по-немецки. Это не выгрузки Wikipedia: нужны связные абзацы, на которых позиционные функции и TF-IDF вообще различимы. Состав коллекции — в таблице 2.1.

Файл	Язык	Область	Предл.	Симв.
ru_medicina.txt	русский	медицина	40	3652
de_medizin.txt	немецкий	медицина	40	3930
ru_iskusstvo.txt	русский	критика искусства	40	3116
de_kunst.txt	немецкий	критика искусства	40	3621

Таблица 2.1 – Тестовая коллекция варианта 22.

Готовые компоненты: FastAPI и Uvicorn, React и Vite, nginx, PostgreSQL, psycopg2, pymorphy3, Snowball, pypdf, matplotlib. Морфология и стеммер нужны, чтобы «пневмонии» и «пневмония», «Quadrante» и «Quadrat» не считались разными терминами. Остальная логика весов написана в `summarizer.py`.

Результаты оценки по эталонной разметке собраны в таблице 2.2. Sentence extraction сравнивается с первыми десятью предложениями. Цифры не подогнаны: эталон специально включает поздние тезисы о деэскалации и о том, что критик обязан описать поверхность.

Метод	P	R	F1	мс
Sentence extraction	0,200	0,200	0,200	1,75
Первые 10 предложений	0,100	0,100	0,100	—
Русский	0,200	0,200	0,200	—
Немецкий	0,200	0,200	0,200	—
Медицина	0,300	0,300	0,300	—
Критика искусства	0,100	0,100	0,100	—

Таблица 2.2 – Средние метрики на четырёх эталонных текстах, по языкам и областям.

Эталон специально сдвинут к поздним тезисам: деэскалация, три узла медицинской схемы, граница изображения и обязанность критика описать поверхность. База из первых десяти предложений даёт F1 0,100. Sentence extraction поднимает оценку вдвое, потому что находит CURB-65, стартовую схему и отказ от эмпирических антибиотиков при вирусной пневмонии. На критике искусства Posd сильнее опускает конец, и F1 остаётся 0,100. По языкам цифры совпадают: тексты параллельны. Время на этих объёмах остаётся миллисекундами. Сравнение показано на рисунках 2.9 и 2.10.




Рисунок 2.9 – F1 sentence extraction и базового метода.




Рисунок 2.10 – Время построения реферата по документам.

Если F1 весового метода недалеко от базы, это не ошибка расчёта. Функции Posd и Posp по методичке сильно поднимают начало текста, а информативные выводы в учебных статьях часто стоят в конце. Это видно по таблице весов на карточке документа: позднее предложение может иметь высокий Score и низкий итог.

Заключение

Реализована система автоматического реферирования для варианта 22: русский и немецкий, медицина и критика изобразительного искусства. Классический реферат собирается методом sentence extraction по формулам методички. Рядом строится дерево ключевых слов и семантическая сеть OSTIS: узлы-понятия и дуги-отношения. На выходе есть ссылка на исходный документ, сохранение в файл и печать.

Оценка на четырёх эталонных текстах показывает, что веса отличаются от простого отбора начала: F1 sentence extraction вдвое выше базы. Позиционные функции всё равно опускают поздние тезисы критики. Система применима как учебный стенд: формулы прозрачны, коллекцию можно расширять своими PDF.

Перспектива — учитывать анафору и сжимать выбранные предложения, как допускает методичка для классического реферата.

Список использованных источников

- [1] Лабораторная работа «Автоматическое реферирование документов». Кафедра ИИТ БГУИР.
- [2] Маннинг К., Рагхаван П., Шютце Х. Введение в информационный поиск. — М. : Вильямс, 2011.
- [3] OSTIS. Open Semantic Technology for Intelligent Systems [Электронный ресурс]. — Режим доступа: <https://ostis-dev.github.io/>.
- [4] FastAPI documentation [Электронный ресурс]. — Режим доступа: <https://fastapi.tiangolo.com/>.
- [5] Korobov M. Morphological Analyzer and Generator for Russian and Ukrainian Languages // Analysis of Images, Social Networks and Texts. — 2015.