

Тема 14. ОСНОВЫ ТЕОРИИ РЕЧЕОБРАЗОВАНИЯ

Основы теории речеобразования

1. Спектрально-временные характеристики речевого сигнала

Ключевые понятия:

речь, звук, гармонические составляющие, осциллограмма, спектр, частота, амплитуда, фаза.

Речь – это сложное физическое явление. Она образуется в результате прохождения воздушных потоков через речевой тракт человека. В результате всевозможных акустических преобразований происходит формирование различных звуков речи. Механизм речеобразования человека представляет собой акустическую трубу, возбуждаемую либо квазипериодической последовательностью импульсов, генерируемых голосовыми связками, либо турбулентным потоком воздуха, проталкиваемого сквозь сужения, в разных местах речевого тракта.

С акустической точки зрения звук – это колебательные движения среды. Сложность речи заключается в том, что это не один колебательный процесс. Речевой сигнал состоит из множества гармонических составляющих, т.е. колебаний, которые периодически изменяются во времени по синусоидальным законам (рис. 3.1, 3.2) и описываются следующим уравнением:

$$S(t) = A \cdot \cos(F \cdot t + \varphi),$$

где A – амплитуда колебаний;

F – частота ($F = 1 / T$);

t – время;

φ – фаза.




Рисунок 3.1. Синусоидальное гармоническое колебание




Рисунок 3.2. Сигнал из нескольких гармонических составляющих с разными значениями периода, амплитуды и фазы

Итак, любые гармонические колебания характеризуются тремя параметрами: частотой F , амплитудой A и фазой. При этом частота (F) колебаний обратно пропорциональна периоду: $F = 1 / T$.

Речевой сигнал, как и любой сложный сигнал, является результатом сложения нескольких гармонических составляющих, каждая из которых характеризуется своими значениями указанных параметров. Каждая такая составляющая называется гармоникой. Например, на рис. 3.3 приведен пример сложения двух гармонических составляющих.




Рисунок 3.3. Пример получения сигнала из нескольких гармонических составляющих

В результате разложения речевого сигнала на входящие в его состав гармонические колебания получается частотный спектр – амплитудно-частотная зависимость. Например, если для сигнала, изображенного на рис. 3.3, частота и амплитуда первой гармоники равны F_1 и A_1 соответственно, а второй – F_2 и A_2 , то получим амплитудно-частотную зависимость, представленную на рис. 3.4.




Рисунок 3.4. Представление сигнала в виде частотного спектра

Для более сложного сигнала амплитудно-частотная зависимость будет включать гораздо большее количество вертикальных отрезков с разными значениями частоты и амплитуды. В этом случае используется другое, более наглядное представление указанной зависимости в виде огибающей кривой линии (рис. 3.5).




Рисунок 3.5. Частотный спектр сигнала в виде кривой линии

Спектр речевого сигнала выражает его частотный состав, т.е. самыми главными характеристиками речевого сигнала являются значения частот его гармонических составляющих. Именно в результате наложения этих частот и их восприятия органами слуха мы получаем возможность слышать богато украшенный звук (речевой сигнал), несущий, кроме того, смысловую составляющую (см. [пункт 3.1.2](#)). Для разложения речевого сигнала в спектр, как правило, используется преобразование Фурье [8, 10] (Рылов А.С.2003кн-Анализ Р; Рабинер Л.Р..1981кн-Цифро О Р С). На практике такое разложение речевого сигнала представляется в виде так называемых динамических спектрограмм (сонограмм).

Сонограмма – это трехмерное изображение динамики артикуляторных процессов в речевом тракте. По оси абсцисс откладывается время, по оси ординат – значения частот, а степень их зачернения соответствует энергии (амплитуде) частотных компонент в спектре сигнала (рис. 3.6).




Рисунок 3.6. Трехмерное изображение динамической спектрограммы речевого сигнала

Речевой сигнал, как и любой другой звук, воспринимается органами слуха человека благодаря тому, что указанные колебательные процессы приводят в возбуждение мембрану, которая посылает в мозг человека соответствующие импульсы. Примерно по такому же принципу устроен и микрофон.

Благодаря описанным колебательным процессам, происходит образование речевого сигнала. Для изучения речевого сигнала необходимо его представить в виде набора некоторых физических и математических составляющих, которые можно изобразить в виде графиков соответствующих функций. Основными способами изображения (описания) речевого сигнала являются:

- спектр – разложение амплитудно-частотных зависимостей;
- осциллограмма – амплитудно-временная зависимость.

Представление речевого сигнала в виде осциллограммы можно увидеть в любом редакторе звука. Например, с помощью любых встроенных средств записи звука на компьютере, а также широко распространенных более мощных редакторах, таких как Sound Forge (рис. 3.7).




Рисунок 3.7. Фрагмент осциллограммы фонемы [а] (спектр фонемы представлен на рис. 3.5)

Изучение речевого сигнала с помощью исследования осциллограмм позволяет найти некоторые закономерности в образовании отдельных звуков речи, а также в их влиянии друг на друга вследствие эффекта коартикуляции. Однако осциллограмма не содержит полной информации о частотных характеристиках речевого сигнала, так как этот способ описания звука основан на его представлении в виде суммы коротких импульсов, характеризующихся временем появления и амплитудой. Положительной чертой данного подхода является то, что используя его, можно выделить слабый полезный сигнал из шума.

2. Информационная и модуляционная структура речевого сигнала

Ключевые понятия:

«речевая» система связи, источник информации, модулятор, переносчик информации, среда распространения, полиинформативность речевого сигнала, информационная структура речевого сигнала, элементы слухового восприятия, тональный переносчик, шумовой переносчик, импульсный переносчик, модуляция формы спектра, манипуляция переносчиков, модуляция длительности звуков, амплитудная модуляция, частотная модуляция, приемное устройство «речевой» системы связи, блок демодуляции, блок фильтрации элементов информационной структуры.

Трудности, возникающие как при разработке систем автоматического синтеза речи, так и систем автоматического распознавания речи, связаны с чрезвычайной изменчивостью основных характеристики речевого сигнала (РС). Отсутствие законченной модели РС не позволяет грамотно сформулировать требования к первичным синтезирующим и анализирующим устройствам. В результате решения, имеющиеся в настоящее время, сопровождаются большим количеством ошибок. Особенно это касается систем автоматического распознавания речи.

Ниже требования к структурной схеме устройства для первичного анализа будут сформулированы на основе представления о речевом сигнале как о сигнале в специфической «речевой» системе связи. При таком подходе речевой сигнал рассматривается не в отрыве от всего процесса общения, а как следствие речевой связи между двумя и более говорящими. При этом в головном мозге субъектов общения происходят определенные процессы, способствующие, с

одной стороны, образованию речевого сигнала, а с другой – восприятию и пониманию сообщения, передаваемого посредством речи (рис. 3.8).




Рисунок 3.8. Речевая связь между двумя говорящими

Как известно из теории связи, для передачи любых сообщений требуется вполне определенная структура системы связи. Технические системы связи существуют с прошлого века. Эволюция их развития: телеграф, телефон, радио, телевидение, Internet. Естественная биологическая система связи – речевая. Связь используется для передачи сообщений от одного субъекта к другому на расстоянии. Общий вид системы связи представлен на рис. 3.9.




Рисунок 3.9. Общий вид системы связи

Как видно из рис. 3.9, связь предполагает наличие источника информации, модулятора и переносчика информации. Источник управляет модулятором, модулятор – переменными переносчика, переносчик распространяется в пространстве звук, волны, постоянный ток, электромагнитные волны. Затем через среду распространения информация попадает в приемник, где происходит ее демодуляция и декодирование.

Итак, всякая техническая система связи включает такие функциональные элементы, как источники информации, кодирующие устройства, переносчики, модуляторы, системы разделения каналов, демодуляторы, декодеры и др. Естественные системы связи, в частности, устная речь, не являются в этом смысле исключением. Основной особенностью речевого сигнала, вытекающей из такого рассмотрения, является его полиинформативность и полимодуляционность.

Полиинформативность речевого сигнала заключается в многообразии типов информации, передаваемой с помощью речи (рис. 3.10). Информация, заключенная в речевом сигнале, может быть разделена на два вида [8] (Рылов А.С.2003кн-Анализ_Р):

- основная, т.е. смысловое содержание речи (семантика высказывания);
- дополнительная, т.е. информация об индивидуальных особенностях говорящего, его физическом и эмоциональном состоянии, а также характеристики передающей среды.



Рисунок 3.10. Виды информации, заключенной в речевом сигнале

Учет всех видов информации важен как в случае синтеза речи, так и в процессе ее распознавания. При этом очевидно, в обоих случаях главным является смысловое содержание речи. В случае синтеза речи этой информации достаточно, для того чтобы передавать информацию пользователю технической системы с помощью синтезированной речи. Конечно, качество (в особенности разборчивость и естественность – см. [пункт 1.2.1](#)) синтезированной речи также играет не последнюю роль, так как человек в этом случае лучше воспринимает смысл. Но в некоторых случаях параметром естественности речи можно пренебречь. В случае же анализа и распознавания речи все указанные виды информации уже содержатся в анализируемом речевом сигнале и многими разработчиками именуются избыточными, так как зачастую препятствуют качественному распознаванию смысла сообщаемого. Для того чтобы отделить различные виды информации, заключенной в речевом сигнале, друг от друга, необходимо детально рассмотреть его структуру и процесс речеобразования в целом.

Вернемся к рассмотрению речевого сигнала в «речевой» системе связи. Рассмотрим более подробно структуру передатчика и приёмника в речевой системе связи. В передатчике определим схему формирования информационной структуры речевого сигнала (рис. 3.11).

Сначала выделим и уточним самые важные виды информации (см. также рис. 3.10), которые передаются по каналу связи:

1. смысловая информация (в процессе общения человек пытается передать информацию, содержащую некоторый смысл);
2. индивидуальность голоса и речи (слушая речь, мы получаем информацию не только о том, что говорится, но и том, кто говорит);
3. эмоциональное и физическое состояние человека (по речи мы можем определить, человек взволнован или спокоен, охрип или с заложенным носом)
4. информация о характеристиках среды и каналах передачи (на слух мы можем определить, используется ли, например, высококачественное вещание или это передача по узкополосному телефонному каналу).




Рисунок 3.11. Схема формирования информационной структуры речи

Указанные виды информации связаны со слуховым восприятием. Смысл речевого высказывания передается с помощью фонетики и, в меньшей степени, просодики (см. [раздел 2](#)). Канал связи меняет тембр звука, вносит искажения и помехи.

Определим элементы слухового восприятия:

- фонетический состав;
- просодика (интонация);
- тембр звука;
- громкость звука;
- высота голоса;
- темп речи;
- искажения и помехи.

В «речевой» системе связи имеется, по крайней мере, 3 типа переносчика информации:

- тональный, с помощью которого передается тон (колебания голосовых связок) – это периодический переносчик;
- шумовой, переносящий шум в речи;
- импульсный, с помощью которого передаются импульсы (взрывы) в речи.

Рассмотрим теперь физику работы описанной схемы формирования информационной структуры речи. Генерирование речевого сигнала связано с функционированием трех источников звука – переносчиков: тонального, шумового и импульсного (рис. 3.11). Передача информации осуществляется путем модуляции некоторых параметров каждого из указанных переносчиков.

Как видно из рис. 3.11, наибольшее число видов модуляции, а следовательно, и наибольшую информационную емкость имеет тональный переносчик, а наименьшую – импульсный. Переносчики включаются или выключаются в связи с фонетическим составом сообщений. Каждый из переносчиков может менять свои параметры, т.е. может происходить:

- модуляция формы спектра или спектральная модуляция – несет наибольшую нагрузку и моделирует все источники (коэффициенты a_k и b_k), она модулирует и тональный переносчик.
- манипуляция переносчиков (включение / выключение переносчиков, связана с фонетическим составом сообщений);
- модуляция длительности звуков – это просодика, фонетика, темп.
- амплитудная модуляция – ей подвергаются все типы переносчиков. Есть громкие фонемы ([а]) и тихие ([ф], [м]). Амплитуда играет роль при передаче фонетики, просодики (главный элемент просодики – ударение, оно характеризуется амплитудой);
- частотная модуляция (модуляция частоты основного тона) – участвует в передаче просодической информации: передает эмоциональное состояние человека через высоту его голоса, воздействует только на тональный переносчик.

Ни один из видов модуляции не передается одним источником. Почти все типы модуляции используются для передачи нескольких источников информации. Типы переносчиков со временем меняются: иногда – только тон, иногда – только шум и т.д. Такая модуляция называется манипуляцией. На выходе системы добавляются помехи и в результате получается речевой сигнал.

Роль каждого вида модуляции в передаче элементов информационной структуры речевого сигнала поясним на примере передачи информации о фонемном составе и интонации речи.

При передаче информации о фонемном составе речи осуществляется непрерывный процесс перестройки речевого тракта. Это приводит к непрерывному изменению формы мгновенных спектров речевого сигнала – модуляция формы спектров – и его средней мощности – амплитудная модуляция. При перестройке речевого тракта осуществляется также фазовая модуляция, хотя полной ясности ее роли в восприятии речевых звуков нет. Кроме того, процесс передачи информации о фонемном составе связан с постоянной сменой комбинаций включения переносчиков – манипуляция переносчиков – и с изменением частоты основного тона на смычках звонких взрывных звуков – частотная модуляция. Информация об интонационной окраске речи, а также о физическом и эмоциональном состоянии, об индивидуальных особенностях голоса и характеристике электроакустической среды передается в основном путем модуляций частоты основного тона – частотная модуляция – и общего уровня звуков – амплитудная модуляция.

Рассмотренная схема передающего устройства речевой системы связи не претендует, конечно, на полноту охвата всех возможных видов передаваемой и получаемой информации, а также всего разнообразия видов модуляции. На схеме рис. 3.11 не указана такая важная операция, непосредственно предшествующая модуляции переносчиков, как кодирование передаваемых сообщений. Однако в целом из рассмотрения схемы на рис. 3.11 можно сделать несколько важных выводов:

- в процессе речевого общения осуществляется параллельная передача различных видов информации;
- для передачи информации каждого вида одновременно используются несколько видов модуляции;
- ни один из видов модуляции (кроме манипуляции переносчиков) не используется только для передачи одного вида информации.

Учитывая указанные особенности формирования речевого сигнала, можно сформулировать вполне определенные требования к схеме его обработки в приемном устройстве (анализаторе).

1. При анализе заданного элемента информационной структуры должна осуществляться демодуляция (детектирование) речевого сигнала по каждому виду модуляции, посредством которой ведется его передача.
2. Результат детектирования по каждому виду модуляции должен быть инвариантен относительно остальных видов модуляции. Возможным методом достижения такого рода инвариантности является осуществление предварительной нормализации речевого сигнала.
3. Если с помощью данного вида модуляции одновременно осуществляется передача еще из других элементов информационной структуры, то полученный в результате демодуляции сигнал должен быть подвергнут дальнейшим операциям разделения.

Итак, речевой сигнал на выходе – сложное информационное явление. Задача приемника – получить нужный тип информации на выходе. Чтобы распознать смысл, нужно разобрать фонетический состав сообщения и т.д.

Рассмотрим схему приемного устройства «речевой» системы связи (рис. 3.12).




Рисунок 3.12. Схема приемного устройства «речевой» системы связи

Приведенная на рис. 3.12 схема приемного устройства «речевой» системы связи является гипотетической и построена в соответствии с указанными выше требованиями к ней. Согласно данной схеме, речевой сигнал одновременно поступает на входы блока демодуляции. Блок демодуляции состоит из собственно демодулятора (детектора данного вида модуляции) и нормализатора по основным видам модуляции. С выходов демодуляторов медленно меняющиеся сигналы (модулирующие) поступают на блок фильтрации элементов информационной структуры. Осуществление фильтрации возможно благодаря разному частотным диапазонам, используемым при передаче различных видов информации. Так, если рассмотреть информационный состав результата демодуляции формы спектра, то оказывается, что информация о фонемном составе заключена в сравнительно быстрых изменениях спектра (от звука к звуку), информация об эмоциональном и физическом состоянии говорящего – в значительно более медленных (от состояния к состоянию). Еще более медленные изменения спектра связаны с передачей информации об индивидуальных особенностях голоса диктора (от диктора к диктору) и о характеристиках среды.

Полученные на выходе блока фильтрации непрерывные, медленно меняющиеся параметры используются затем как входные сигналы для блоков декодирования. Эти параметры образуют, во-первых, полную систему для любого вида информации, и во-вторых, их значения не зависят от изменений в речевом сигнале, связанных с передачей других видов информации. Если мы сможем демодулировать каждый тип сигнала, выделить каждую составляющую, а потом все собрать, то получим полную информацию о сигнале. Получение полной системы таких параметров и является основной задачей первичного анализа речевых сигналов. Эта схема ничего не говорит о подходах, а только о том, насколько речь – сложное явление (как и любое биологическое явление).

Методы анализа речевого сигнала

Метод цифровой фильтрации

В этом методе реализуется наиболее простой и понятный подход к спектральному разложению сигналов. Анализаторы, основанные на данном подходе, состоят из набора параллельно включенных цифровых полосовых фильтров, спектральные характеристики которых представляют собой узкие примыкающие друг к другу полосы, перекрывающие необходимый диапазон частот. Для получения спектра сигнала достаточно измерить значение мощности на выходе каждого фильтра и рассматривать их как точки спектра, соответствующие центральным частотам полос пропускания. Практически формирование вектора параметров в задачах распознавания речи осуществляется на основе способа «кадр-за-кадром» с их пошаговым перекрытием. Поскольку с каждым новым шагом изменяется только часть данных, такой способ сегментирования гарантирует отслеживание всех акустических явлений в речевом сигнале, обеспечивая в то же время достаточно плавное изменение параметров от выборки к выборке. Поэтому на выходе каждого канала «кадр-за-кадром» вычисляются оценки значений мощности, которые используются в качестве компонент вектора спектральных параметров описания речевых сигналов.

Спектральный анализ с использованием алгоритмов БПФ

Быстрое преобразование Фурье (БПФ) - это название целого ряда эффективных алгоритмов, предназначенных для вычисления дискретно-временного ряда Фурье. Основы построения таких алгоритмов, аппаратная и программная реализация, а также принципы их применения для спектрального анализа подробно освещены в ряде работ [14, 15] (Крот А.М.1995кн-Быстр_А_и_П; Власенко В.А..1990кн-Метод_С_Б_А). Поскольку, как правило, спектр дискретизируется с достаточно тонким разрешением, большое количество отсчетов спектра, получаемых с помощью алгоритмов БПФ, не позволяет использовать их напрямую в качестве параметров описания речевых сигналов и требует некоторой процедуры сглаживания, к примеру, в виде взвешенной суммы полученных значений спектральных плотностей мощности, лежащих внутри заданного «канального» диапазона частот. Поэтому на основе спектрального анализа через алгоритмы БПФ для формирования вектора параметров описания речевых сигналов обычно используют взвешенные поканальные значения мощности.

Использование в распознавании речи гомоморфных параметров, к числу которых можно отнести кепстральные коэффициенты [8] (Рылов А.С.2003кн-Анализ_Р), позволяет отделить сигнал возбуждения от формы голосового тракта. Кепстр преобразования Фурье представляет собой обратное преобразование Фурье от логарифма спектра.

Спектральный анализ на основе линейного предсказания

Рассмотрим метод коэффициентов линейного предсказания (КЛП или LPC). В этом методе анализа речевого сигнала используется мощная математическая теория, решающая задачу описания нуль-полосной модели речевого сигнала. Основная идея – описание речевого спектра с помощью информации о нулях и полюсах, для этого используется аппарат дифференциальных уравнений и др. математика.

Реальный алгоритм получения параметров описания на основе модели линейного предсказания коротко состоит в следующем. Предположим, что анализируемый случайный процесс является выходом фильтра, на вход которого поступает белый шум. Этот фильтр задается как рекурсивный фильтр с импульсной характеристикой бесконечной протяженности. В той мере, насколько справедлива эта модель, энергетический спектр сигнала описывается выражением

$$P(f) = \frac{T\rho}{\left| 1 + \sum_{k=1}^m a[k] e^{-j2\pi kTf} \right|^2},$$

где T - частота дискретизации. Коэффициенты p , $a[1]$, $a[2]$, ..., $a[m]$ определяются из решения уравнений Юла-Уолкера при помощи рекурсивного алгоритма Левинсона [17] (Марпл-мл. С.Л.1990кн-Цифро_С_А). Уравнения Юла-Уолкера для коэффициентов $a[k]$, $k=1,...,m$ совпадают с уравнениями, возникающими при постановке задачи линейного предсказания [17] (Марпл-мл. С.Л.1990кн-Цифро_С_А). Коэффициенты $a[k]$, $k=1,...,m$ называют коэффициентами линейного предсказания, а спектр, полученный методом авторегрессии, называется спектром линейного предсказания [18] (Picope J.1993art-Signal_M_T). Спектр линейного предсказания, также как и спектр БПФ, в явном виде при обработке речи не используется. Обычно диапазон частот спектра линейного предсказания разбивается на заданное число каналов. Для каждого канала рассчитывается средняя мощность. Эти значения мощности используются как коэффициенты вектора параметров. Коэффициенты линейного предсказания используются также для расчета кепстральных коэффициентов линейного предсказания [8] (Рылов А.С.2003кн-Анализ_Р).

Вектор основных параметров, составленный на базе описанных выше методов не может исчерпывающим образом описать все возможные вариации речи. Несмотря на возможность управления разрешением спектра и увеличения числа кепстральных коэффициентов, это не приводит в конечном итоге к улучшению точности распознавания. Поскольку оценки спектра получаются достаточно сглаженными, увеличение разрешения спектра не дает новой существенной информации о сигнале, поэтому на практике используются не более 20 каналов. В качестве компонент вектора параметров обычно используются не более 14 первых кепстральных коэффициентов, поскольку более высокие коэффициенты практически нечувствительны к изменениям в сигнале.

Ранее уже отмечалось, что при покадровой сегментации для упрощения вычисления векторы параметров разных окон считаются независимыми друг от друга, тем самым теряется информация о динамике речевых характеристик. Однако такая информация может быть восстановлена путем аппроксимации производной каждого параметра конечной разностью по нескольким последовательным выборкам речевого сигнала. Полученные таким образом величины, являющиеся по сути производными от основных параметров, позволяют добавить весьма важную информацию в вектор параметров и носят название дельта-параметров.

Если вектор параметров обозначить как $\mathbf{p}$, где $\mathbf{p}_i$ – компоненты вектора речевых параметров, d – размерность вектора, а вектор параметров для n -го окна как $\mathbf{x}_n$, то последовательность X векторов параметров при покадровой обработке есть $X = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_M\}$. Таким образом, при помощи рассмотренных выше алгоритмов на выходе блока параметрического описания речевого сигнала формируется последовательность X векторов параметров описания речевого сигнала.

Формантно-параметрическое описание речевого сигнала

Следующий вид анализа РС – получение формантного описания речевого сигнала. Этот метод (см. также [пункт 3.2.4](#)) позволяет получить наиболее ценную информацию о самых значимых максимумах и минимумах спектра и их параметрах.

Для задачи распознавания речи, как уже определено выше, наиболее адекватны параметры формантной модели описания речевого сигнала. На основе этих методов разрабатываются многочисленные процедуры оценки параметров способа образования – главным образом параметров источников возбуждения (Rouat G..1995art-Pitch_D), и места образования – главным образом формантных частот (Schmid P..1995art-N-Best_F_T; Potamianos A..1995art-Spec_F_F; Sun D.X.1995art-Robus_E; Holmes W.J..1997art-Using_F_F).

В [пункте 3.2.4](#) рассмотрена формантная модель акустики речевого тракта. В рамках этого рассмотрения выделены 10 управляющих параметров указанной модели и показана зависимость первой и второй формант гласных, а также эффект коартикуляции, т.е. влияния гласных на формантные характеристики согласных фонем русской речи. Здесь продолжим это рассмотрение.

Для дальнейшего разделения согласных по месту образования используются параметры F3, Fф, Вф, Аа. Основную роль в разделении мягких согласных играет параметр F3 (рис. 3.24), в разделении зубных и альвеолярных согласных – параметр Fф (рис. 3.25).



Рисунок 3.24. Разделение мягких согласных по параметру F3




Рисунок 3.25. Разделение зубных и альвеолярных согласных по параметру Fφ

Дополнительное выделение группы губных согласных осуществляется по параметру Вф, который равен 1 только для этой группы, а для остальных фонем равен 0. Аналогично параметр Аа = 1 только для группы небных согласных и благодаря этому участвует в их дополнительном выделении.

В разделении фонем по способу образования важную роль играют значения параметров Ар, Аф, Аа, Ан, F1, F0, определенные на участке ядра фонемы. Не менее важной является также временная организация этих параметров, которая в значительной степени определяется способом образования фонем. На временных диаграммах рис. 3.26 отражены значения параметров Ар, Ан, Аф, Аа, характеризующие ту или иную группу согласных, а также временные

особенности их развития в контексте гласный - согласный - гласный.




Рисунок 3.26. Временные диаграммы изменения А-параметров для согласных разного способа образования

Метод кепстральных коэффициентов

Еще одним активно используемым в настоящее время методом анализа РС является метод кепстральных коэффициентов (рис. 3.20). Слово "CEPSTRUM" произошло от слова "SPECTRUM" и вторично по отношению к нему. Так как при спектрально-полосном кодировании берутся отдельные отсчеты спектра (рис. 3.20, а), а при кепстральном кодировании применяется вторичное разложение отсчетов спектра в ряд Фурье, рассматриваются синусоиды для каждого отсчета (рис. 3.20 б, в) и рассчитываются спектральные коэффициенты (C_n) для каждого отсчета (S_i) по формуле


$$C_n = \sum S_i \cos(n\pi(i - 0,5)/I).$$


Рисунок 3.27. Метод кепстральных коэффициентов

Особенности восприятия речи

Еще одним очень важным направлением исследований особенностей естественной речи является исследование вопросов восприятия речи человеком. Результаты, полученные в этом направлении, могут оказать важное влияние на разработку методов автоматического распознавания речи. Самым любопытным в данных исследованиях является тот факт, что человек умеет слышать и воспринимать речь в различных условиях и в разных состояниях. Слух человека способен отличить речь от других звуков, которые его окружают. При этом решается самая главная задача – понимание. Кроме того, слух человека и его способность слушать и понимать услышанное является результатом высшей нервной деятельности, присущей только разумному существу [19] (Лосик Г.В.2000кн-Перце_Д).

Каким образом организован процесс слуха у человека? Что в действительности воспринимают органы слуха? Как они устроены? Что и как помогает человеку понимать смысл того, что он слышит, даже в условиях плохой слышимости? Вот некоторые из вопросов, на которые пытаются ответить ученые, изучая природу человеческого слуха. Разумеется, все получаемые ответы интерпретируются в терминах технических систем, если ставится задача разработки систем автоматического распознавания речи.

1. Свойства слухового восприятия речи человеком

Несмотря на специфичность речевой системы связи в ней, во всяком случае на этапе речеобразования, можно выделить элементы, присущие передающей стороне технической системы связи:

- источник сообщения - мозг человека;
- элементы сообщения - слова, слоги, звуки (фонемы);
- кодирование - генерирование сигналов управления органами артикуляции соответственно элементам сообщения;
- переносчики информации - сигналы возбуждения речеобразующего тракта;
- модуляторы - органы артикуляции.

Отмеченное подобие и является основанием для проведенного выше анализа структурных свойств речевого сигнала с позиции технических систем передачи информации. Однако рассмотренная выше структура гипотетической «речевой» системы связи достаточно хорошо обоснована лишь в части ее передающей стороны, отражающей свойства процесса образования и передачи речевого сигнала. Для уточнения требований к приемной стороне речевой системы и ее структуре необходим более глубокий не только качественный, но и количественный анализ свойств образования и восприятия речевого сигнала.

"Как только мы определим конечный результат восприятия речи как понимание смысла сообщения и потребуем, чтобы можно было понимать никогда не слышанные ранее предложения, сразу же становится очевидным, что процесс восприятия должен быть организован иерархически. Для того чтобы понять смысл предложения, необходимо располагать описанием синтаксической структуры этого предложения. Для того чтобы произвести синтаксический анализ, необходимо, чтобы предложение было сначала расчленено на слова, и каждому слову были приписаны его лексические и грамматические характеристики. Чтобы проанализировать слово, нужно предварительно располагать его фонемным или близким к фонемному описанием. Наконец, для того чтобы преобразовать речевой сигнал в последовательность фонем, в этом сигнале нужно сначала выделить акустические признаки, по которым фонемы отличаются друг от друга. Выделение акустических признаков предполагает предварительное спектрально-временное описание стимула" (Деркач М.Ф..1971кн-Воспр_Р).

Приведенное логическое обоснование структуры технической модели распознавания речи опирается на отдельные изученные свойства восприятия речи человеком и носит обобщенный характер. Основными этапами иерархической модели восприятия смысловых сообщений, в порядке их следования от нижних ступеней к верхним, принято считать следующие:

- уровень слухового (рецептивного) восприятия речевого сигнала;
- уровень восприятия слуховых признаков речи;
- уровень восприятия минимальных смыслоразличительных элементов речи;
- уровень лексического анализа (распознавание слов);
- уровень синтаксического анализа (распознавание фраз);
- уровень семантического анализа (распознавание смысла сообщений).

Для создания технических систем распознавания речи в первую очередь представляют интерес первые три из названных выше уровня восприятия речевого сигнала.

2.Свойства рецептивного восприятия речевых сигналов

Слуховой аппарат человека, как известно, способен воспринимать и анализировать акустические сигналы, существенно отличные от речевых как по динамическому и частотному диапазонам, так и по своей природе. Поскольку в силу эволюционного развития речь появилась на более поздних его этапах, можно ожидать, что для восприятия акустических сигналов самого различного происхождения слуховой анализатор должен обладать некоторыми универсальными свойствами. И действительно, как показали опыты по восприятию [20] (Бондарко Л.В..1968кн-Модел_В_Р), слуховой анализатор одинаково хорошо справляется с анализом как коротких (импульсных), так и длительных сигналов, как чистых тонов, так и сложных сигналов, как стационарных, так и изменяющихся во времени (модулированных) сигналов. Одним из важных проявлений универсальности слухового анализатора состоит в том, что он обладает высокой разрешающей способностью как по частоте, так и по времени.

Высокая разрешающая способность по времени указывает на то, что частотная избирательная система слухового анализатора на первичном (рецепторном) этапе восприятия должна быть эквивалентна набору широкополосных фильтров. И действительно, снятые экспериментально амплитудно-частотные характеристики основной мембраны обнаружили низкую (порядка единицы) добротность избирательных фильтров слухового анализатора. Было установлено, что основная мембрана эквивалентна анализатору спектра с малой разрешающей способностью по частоте, но с высокой разрешающей способностью по времени. Высокую разрешающую способность по частоте слуховой анализатор приобретает на последующих этапах обработки информации, на нейронном уровне (Молчанов А.П., 1970ст-Механ_А_С). При этом возможны различные механизмы повышения разрешающей способности по частоте – как путем обострения частотных характеристик основной мембраны (Молчанов А.П., 1970ст-Механ_А_С), так и путем оценки величин, обратных интервалу времени между импульсами возбуждения нейронов, т.е. путем временного анализа функций возбуждения эквивалентных фильтров основной мембраны. Последнее предполагает запоминание прошлых значений сигналов возбуждения основной мембраны на некоторое время. Хотя из-за методологических трудностей прямых доказательств этого получить не удалось, но изученные свойства слуховосприятия хорошо согласуются с гипотезой о существовании такого механизма.

Таким образом, накопленные данные о свойствах слухового анализатора свидетельствуют в пользу того, что:

- на первом рецептивной уровне (уровне ощущения) используется полное описание акустического сигнала в виде несглаженных частотно-временных функций возбуждения основной мембраны, запоминаемые в кратковременной оперативной памяти с временным окном порядка 70-150 мсек, т.е. описание сигнала в виде спектрально-временного рельефа, образующегося с помощью гребенки широкополосных фильтров основной мембраны;
- в зависимости от того, какая решается задача – сравнение сигналов (установление тождества или различия, определение степени сходства сигналов) или оценка сигнала (отнесение его к какой-либо группе сигналов, выбор формы реагирования на сигналы той или иной группы) – используется, соответственно, или полное спектрально-временное описание сигналов, или их сокращенное описание в терминах параметров и признаков спектрально-временного описания, полезных в данной ситуации;
- переход к сокращенному описанию сигналов по полезным параметрам и признакам относится к следующему за перцептивным этапом обработки информации [19] (Лосик Г.В. 2000кн-Перце_Д), а сами параметры и признаки – к приобретенным в процессе обучения.

3. Природа слуховых (фонетических) признаков речевого сигнала

Естественно, представляет большой интерес вопрос о том, какими параметрами и признаками представляется сокращенное описание речевого сигнала в слуховом анализаторе человека. На основании обширного обзора работ в [20] (Бондарко Л.В., 1968кн-Модел_В_Р) делаются следующие выводы о свойствах слухового описания речевых сигналов:

- при восприятии сложного сигнала делается суждение о характере сигнала: периодический, шумовой, импульсный, причем восприятие характера сигнала не нарушается при его значительных спектральных искажениях;
- при длительности сигналов меньше 15-20 мс человек не определяет его временной структуры и относит его к классу импульсных сигналов;
- выделяются три класса сигналов с разрешаемой временной структурой: периодические сигналы, амплитудно-модулированные шумы и сплошные шумы;
- различаемые классы сигналов используются как слуховые признаки способа образования звонких, фрикативных, звонких фрикативных и взрывных звуков речи;
- при идентификации смыслоразличительных единиц речи человек пользуется не полным спектрально-временным описанием речевого сигнала, а некоторыми его параметрами. Наиболее важными из них являются частоты формант, частота основного тона и интенсивность;
- слуховой анализатор выделяет "особые точки" в изменяющихся во времени параметрах речевого сигнала. Так, например, при классификации гласных используются значения формантных частот в точках перегиба их изменений;
- направления сдвига частот формант относительно их значений на стационарных участках (в точках перегиба) гласных являются признаками для различения места образования ряда согласных;
- скачкообразные изменения частоты основного тона относительно значений на гласном являются различительным признаком ряда согласных;
- скорость изменения и величина относительного перепада интенсивности также являются различительными признаками согласных звуков речи;
- в слуховой системе измеряются интервалы между особыми точками (моментами перегиба формантных частот, начала и конца глухой смычки, шумовых сегментов, перепадами интенсивности и частоты основного тона и др.), а значения интервалов сами выступают в роли слуховых признаков речевых стимулов.

Итак, есть основания считать, что сокращенное описание речевого сигнала в слуховом аппарате человека формируется в виде:

- формантных параметров, извлекаемых из полного описания речевого сигнала (несглаженного спектрально-временного рельефа);
- сигнальных признаков, извлекаемых из полного описания речевого сигнала и характеризующих классы сигналов (импульсный, периодический, шумовой, амплитудно-модулированный шум);
- параметрических признаков, извлекаемых из параметрического описания речевого сигнала и характеризующих

отдельные свойства параметров (значения в особых точках, относительные свойства параметров, направления и скорости изменений параметров во времени и др.);

- временных признаков, извлекаемых из временных параметров сигнальных и параметрических признаков (длительностей и временных интервалов между признаками) и характеризующих их временные свойства.

4. Свойства восприятия минимальных смыслоразличительных элементов речи

Признаки, свойственные минимальным смыслоразличительным элементам речи – фонемам, составляют основу для первичного их восприятия (текущего фонемного кодирования речевого сигнала, допускающего исправление ошибочных фонемных решений на последующих уровнях восприятия речи). Свойства восприятия на этом этапе говорят о том, что информация о фонемных образах распределена во времени. При этом группам звуков присущи свои особенности распределения во времени. Если условно принять фразу смыкания артикуляторов при образовании звуков речи за сегмент собственного согласного, а фразу размыкания – за сегмент собственного гласного, то по относительной доле информативности этих сегментов звуки речи группируются следующим образом [20] (Бондарко Л.В..1968кн-Модел_В_Р):

- информация о гласных сосредоточена на их стационарных сегментах (в особых точках);
- сегмент собственно согласного фрикативных несет всю необходимую информацию для выбора фонемы;
- сегмент собственно согласного сонорных несет сведения для выбора фонемы, однако их недостаточно для безошибочного распознавания. Важна информация о переходных сегментах;
- смычка звонких взрывных выступает в роли группового признака и почти не несет информации о выборе фонемы. Основная информация для выбора фонемы определяется признаками переходных сегментов;
- для глухих взрывных в начальном положении вся информация содержится в переходном сегменте, для конечных глухих взрывных важным является также и сегмент взрыва.

Таким образом, распределение информации в речевом потоке носит неравномерный характер. Перераспределение и преобразование информации в дискретные фонемные решения происходит в пределах отрезка речевого потока, превышающего по длительности звук речи в обычном понимании этого слова. Этим во многом объясняется, почему два сходных отрезка речевого потока, соотносимые с отдельными речевыми звуками в различном окружении могут реализовываться как две различные фонемы и наоборот – два различных отрезка – как одна фонема. Это говорит о том, что число фонемных образов в пространстве слуховых признаков больше числа фонем, определяемых лингвистами.

Относительно механизма принятия решений на основе слуховых признаков имеющиеся экспериментальные данные содержат довольно мало сведений. Они скорее указывают на то, каким требованиям должна отвечать модель распознавания фонем.

Одно из требований состоит в том, что процедура распознавания фонем должна обеспечивать сбор информации, содержащейся в слуховых признаках различной природы и распределенной по времени на участках речевого потока, соотносимых по длительности со слоговыми элементами речи. Об этом свидетельствуют приведенные выше свойства слухового восприятия и описания фонем, а также результаты экспериментов по текущей имитации звуко сочетаний.

Другое требование состоит в том, что случаи неопределенности не должны приводить к пропуску фонем, т.е. в последовательности фонемных решений должно быть отмечено место нераспознанного элемента речи. Об этом свидетельствуют результаты эксперимента по восприятию речевых сигналов, подверженным сильным частотным искажениям. Анализ ошибочно принятых фраз показал, что хотя они значительно отличались от исходных по звуковому составу, число слогов, последовательность смены гласных и согласных и места ударений распознавались практически безошибочно.

Способность человека безошибочно воспринимать чередование гласных и согласных и, как отмечено выше, различать классы сигналов (периодический - шумовой) при сильных частотных искажениях сигнала, а также воспринимать перепады интенсивности и частоты независимо от их абсолютных значений указывает на высокую устойчивость и, соответственно, надежность восприятия признаков, связанных со способом образования звуков речи. Менее устойчивыми оказываются признаки типа значений формантных частот в особых точках. Было установлено, что фонемное качества таких точек для первой и второй формантных частот зависит от частоты основного тона и частот более высших формант, т.е. связано с индивидуальными формантными характеристиками диктора. Отсюда следует третье требование к модели восприятия фонем, которое состоит в необходимости адаптации (подстройки) модели к ансамблю частотных параметров, представляющих определенного диктора.

Итак, изученные свойства восприятия речи человеком согласуются с иерархической структурой ее модели. Одно из преимуществ такой структуры заключается в том, что каждый из последовательных ее блоков может быть относительно более простым, обходиться меньшими объемами оперативной и долговременной памяти сравнительно с одноступенчатой моделью. Это связано с тем, что каждый предыдущий блок выполняет роль фильтра информации по отношению к последующему блоку, уменьшает размерность сигналов и приводит их к форме более удобной для дальнейшей обработки. Другое важное преимущество иерархической структуры модели состоит в том, что если информация, поступающая на вход данного блока оказывается недостаточной, может быть принято несколько альтернативных решений с указанием их апостериорных вероятностей, а принятие окончательного решения может быть оставлено на последующие этапы вплоть до последнего этапа - распознавания смысла высказывания.

Свойства слухового описания и восприятия речевых сигналов, важные для выработки требований к методам анализа речевых сигналов в концентрированном виде сводятся к следующему:

- на уровне рецептивного восприятия любые сигналы, в том числе и речевые, отображаются в виде нестлаженного спектрально-временного рельефа;
- минимальные смысловоразличительные элементы речи фонемы и их различительные (дифференциальные) признаки описываются слуховыми (акустическими) признаками, приобретаемыми в процессе обучения речи;
- слуховые признаки связаны со структурными и параметрическими (формантными) свойствами спектрально-временного описания, являющимися следствием артикуляции звуков речи, т.е. с акустическими признаками артикуляции;
- решение о дифференциальных (различительных) признаках фонем принимается на интервале времени реализации артикуляции слогового комплекса;
- существует иерархия различительных признаков фонем - признаки способа образования распознаются более устойчиво и надежно сравнительно с признаками места образования звуков речи;
- в условиях неопределенности, возникающей в случаях недостаточности акустической информации, ее искажения помехами различного рода, производится неполное распознавание фонем, состоящее в перечислении дифференциальных признаков, которые удалось распознать, а принятие окончательного решения переносится на более высокие уровни восприятия.

Отмеченные свойства слухового описания речевых сигналов на нижних уровнях восприятия безусловно важны для выработки требований к методам их анализа. Однако представляется очевидным, что полная система требований к методам анализа речевых сигналов, а, главное, первоочередные задачи их анализа и распознавания могут быть определены только в рамках целостной модели распознавания речевых

Вопросы и задания на закрепление

1. Сформулируйте свое определение понятия «речь».
2. Объясните понятие «звук» с акустической точки зрения.
3. Перечислите и поясните основные способы описания речевого сигнала.
4. Представьте в виде схемы общий вид системы связи.
5. В чем заключается полиинформативность речевого сигнала?
6. Перечислите основные виды информации, заключенной в речевом сигнале.
7. Изобразите и прокомментируйте схему формирования информационной структуры речевого сигнала в «речевой» системе связи.
8. Какие переносчики информации используются в «речевой» системе связи?
9. Какие виды модуляции происходят в «речевой» системе связи? Поясните на примере.
10. Сформулируйте требования к схеме обработки речевого сигнала в приемном устройстве.
11. Изобразите и прокомментируйте схему приемного устройства «речевой» системы связи.
12. Перечислите и охарактеризуйте основные методы синтеза речевого сигнала.
13. Перечислите и охарактеризуйте основные методы анализа речевого сигнала.
14. Опишите основные особенности восприятия речи.