

Тема 16. МЕТОДЫ СИНТЕЗА РЕЧЕВОГО СИГНАЛА

Ключевые понятия:

обобщающая математическая модель речевого сигнала, импульсно-кодовая модуляция сигнала, метод линейного предиктивного кодирования, фонетическая модель синтеза речевого сигнала, параметрические методы синтеза речевого сигнала, формантная модель акустики речи, компиляционные методы синтеза речевого сигнала, геометрическая модель речевого тракта, передаточная функция речевого тракта, форманта, аллофонная модель, микроволновой метод синтеза речевого сигнала.

В настоящее время существуют различные методы синтеза речевого сигнала. Каждый из методов предлагался разработчиками систем автоматического синтеза речи и преследовал своей целью повысить качество синтеза. Синтез речи фактически представляет собой моделирование способности естественной биологической системы-человека. Это способность говорения. Какие процессы происходят в мозгу человека? Каким образом происходит образование речи у человека? Каким образом устроен речевой аппарат человека? Как происходит образование звуков речи? Какими свойствами обладает речевой сигнал? С помощью каких характеристик можно описать речевой сигнал? Какие именно параметры наиболее адекватно отражают процесс речеобразования? Вот лишь некоторые из вопросов, на которые необходимо попытаться ответить для того, чтобы разработать «искусственную модель речеобразования».

1. Обобщенные математические модели описания речевых сигналов

Проблемы математического описания речевых сигналов на акустическом и лингвистическом уровнях процесса распознавания достаточно полно проанализированы в работах Т.К. Винцюка [9] (Винцюк Т.К.1987кн-Анализ_Р_и_И):



цитата

В рамках приведенной модели возможно как оценивание передаточной характеристики речевого тракта (его полюсов), так и характеристик источника возбуждения (мгновенного периода основного тона, амплитуды сигнала возбуждения, признаков типа тон-шум и т.п.).

Все же в подавляющем числе случаев пользуются не приведенной моделью, а совокупностью моделей, каждую из которых используют для независимой оценки части параметров. Например, по одной модели находят полюса речевого тракта, а по другой вычисляют признаки тон – шум и период основного тона». Происходит это потому, что на практике априори нам неизвестны параметры В, С и D, определяющие природу (классы) составляющих процесс сигналов. Поэтому (3.1) представляет собой скорее модель синтеза речевого сигнала, когда свойства синтезируемого речевого сигнала априори известны из заданного фонетического текста высказывания.

Наиболее системный подход к конструированию математических моделей анализа и синтеза речевых сигналов на акустическом уровне с позиций общей теории информации дан в работе А.В. Чичагова (Чичагов А.В.1991ст-Модели_и_П_О). Выводы, вытекающие из внимательного прочтения этой работы, остаются весьма актуальными и сегодня, в связи с чем остановимся на основных положениях работы (Чичагов А.В.1991ст-Модели_и_П_О) более подробно.

«Речевой сигнал представляет случайный нестационарный процесс, удовлетворительное стохастическое описание которого в настоящее время неизвестно. В качестве рабочей гипотезы, позволяющей приблизиться к математическому описанию речевого сигнала, часто принимают гипотезу локальной стационарности. Согласно этой гипотезе, стохастический процесс, описывающий речевой сигнал, считается стационарным на кратковременных интервалах (сегментах), характерная длительность которых зависит от сложности выбранной стационарной модели. Таким образом, предполагается, что внутри сегмента речевой сигнал описывается некоторой стационарной моделью, а переход от одной стационарной модели к другой (или изменение значений параметров модели) осуществляется на границе соседних сегментов.

В качестве простого примера реализации этой гипотезы можно привести модель синтеза речевого сигнала посредством его прямого восстановления из дискретной (обычно равномерной) выборки или импульсно-кодовой

модуляции сигнала (ИКМ–модель) [10] (Рабинер Л.Р..1981кн-Цифро_О_Р_С). В ИКМ–модели речевой сигнал аппроксимируется постоянной величиной на интервалах длительностью $T_d = f_d^{-1}$, где f_d - частота дискретизации сигнала, которую выбирают выше удвоенной максимальной частоты спектра речевого сигнала. Синтезированный речевой сигнал в этом случае можно представить в виде стохастического процесса с независимыми приращениями

$$x(t) = x_0 + \sum_{n=1}^{\infty} (x_n - x_{n-1}) \delta(t - t_n), \quad (3.2)$$

где $\delta(t) = \begin{cases} 1, & t \geq 0, \\ 0, & t < 0, \end{cases}$ - функция Хэвисайда, x_n - значение сигнала в момент t_n , $t = n T_d$, T_d - длительность интервала дискретизации.

ИКМ–модель позволяет получить высокое качество синтезированного речевого сигнала при выборе частоты дискретизации $f_d > 104$ Гц. Существенным недостатком ИКМ–модели является довольно большой объем априорной информации (знание конкретной реализации дискретного случайного процесса $\{x_n\}$, $n = 0, 1, \dots$), необходимый для определения речевого сигнала.

Преодолеть указанный недостаток ИКМ – модели можно путем увеличения длительности сегментов стационарности за счет некоторого усложнения модели, описывающей речевой сигнал внутри сегмента. Известной моделью более высокого уровня сложности по сравнению с ИКМ–моделью является ЛПК–модель речевого сигнала или метод линейного предиктивного кодирования [11] (Маркел Дж.Д..1981кн-Линей_П_Р). Сущность ЛПК–модели состоит в следующем:

1. Речевой сигнал компилируется (т.е. последовательно составляется) из сегментов длительностью $T_s = f_s^{-1}$, где $f_s \sim 10^3$ Гц - частота сегментации, внутри которых речевой сигнал аппроксимируется (моделируется) некоторой функцией, характеристики которой определяются значением вектора параметров.
2. В качестве модели речевого сигнала на сегменте стационарности обычно выбирается модель авторегрессии – скользящего среднего (АРСС):

$$x_t = \sum_{i=1}^M a_i x_{t-i} + \sum_{k=0}^K b_k \xi_{t-k}, \quad (3.3)$$

где $\{a_i\}$ - параметры авторегрессии, $\{b_k\}$ - параметры скользящего среднего, (M, K) - сложный порядок модели, ξ_t - порождающая последовательность или источник возбуждения. В качестве ξ_t часто принимают либо случайную некоррелированную гауссову последовательность $\{v_t\}$ с характеристиками $M[v_t] = 0$, $M[v_t v_s] = \delta_{ts}$, либо регулярную последовательность единичных импульсов $\{\tau_t = \delta(t - nT_0)\}$, где T_0 - период следования импульсов или период основного тона.

3. По заданной реализации дискретного векторного случайного процесса, где x_t - и произвольной реализации белого шума синтезируют речевой сигнал

При реализации ЛПК–модели обычно принимают $M, K \sim 10$. Таким образом, вектор параметров, занимая объем порядка десяти дискретных значений ИКМ–сигнала, представляет речевой сигнал на сегменте стационарности порядка ста интервалов дискретизации. Следует отметить, однако что ЛПК–модель не позволяет получить высокое качество синтезированного речевого сигнала при существенном (>10) выигрыше в плотности или скорости передачи информации по сравнению с ИКМ–моделью.

«Довольно близкой к естественному представлению является фонетическая модель речевого сигнала. Согласно этой модели речевой сигнал можно представить в виде некоторой последовательности элементарных или базисных звуков, которые для речевого сигнала получили название фонем. В русском языке, например, выделяют 42 фонемы (Зиндер Л.Р.1979кн-Общая_Ф), которые составляют словарь или алфавит фонем русского языка. Более тонкие фонетические исследования позволяют различать вариации фонем в зависимости от контекста – аллофоны, переходные звуки – дифтонги, аффрикаты и т.д. Расширение алфавита за счет "тонкой структуры" фонем не опровергает, однако, предположения, что речевой сигнал можно описать в виде текста, т.е. последовательности знаков определенного алфавита по типу, например, нотной записи музыкального произведения. Каждый знак (символ, элемент) такого алфавита сопоставляется определенному элементарному звуковому сигналу характерной длительности (пауза или "отсутствие сигнала" также является знаком этого алфавита).

Следует также отметить, что рассмотренные математические модели описания речевого сигнала играют важную роль не только при решении задач синтеза речи, но и при решении задач анализа речевых сигналов, а именно задач вокодирования, распознавания речевых сигналов, автоматической идентификации и верификации (см. [подраздел 3.3](#)).

2. Классификация методов синтеза речевого сигнала

Все существующие в настоящее время методы синтеза речевого сигнала делятся на два основных класса (рис. 3.13):

- параметрические;
- компиляционные.



Рисунок 3.13. Методы синтеза речевого сигнала

Параметрические методы синтеза речевого сигнала характеризуются тем, что при их реализации используются знания о том, каким образом осуществляется образование речи у человека и какими параметрами описывается речевой сигнал. Основываясь на этих знаниях, осуществляется моделирование акустических процессов речеобразования. В результате такого моделирования речевой сигнал генерируется подобно тому, как это делается в речевом тракте человека. Моделирование процессов речеобразования человека в системах автоматического синтеза речи осуществляется одним из двух способов:

- на основе знаний об артикуляторных процессах, происходящих в речевой системе человека;
- путем математического описания собственно акустических процессов.

В первом случае целью моделирования является построение адекватной геометрической модели речевого тракта. Во втором – формирования наборов акустических параметров, описывающих речевой сигнал. Наиболее распространенными такими параметрами являются формантные параметры, основанные на формантной модели акустики речи. На основе двух указанных подходов разрабатывались также различные комбинированные методы синтеза речевого сигнала, в частности, артикуляторно-формантный и фонемно-формантный.

Следует отметить, что метод моделирования геометрии речевого тракта дает основания надеяться на получение качественных систем автоматического синтеза речи, максимально приближенных к человеческой речи. Однако трудность заключается в том, что до сих пор нет достаточно полных сведений об особенностях строения речевого тракта человека, так как во многом это связано с большими индивидуальными различиями и трудностями проведения массовых исследований с целью получения обобщенных результатов. Поэтому пока формантные модели являются более развитыми и распространенными. Это связано с тем, что измерение физических (акустических) характеристик осуществить гораздо проще. Проще также обобщить их.

Существуют и другие модели синтеза речевого сигнала, основанные на параметрическом подходе. Например, модель линейного предсказания (КЛП-модель), основанная на использовании так называемых коэффициентов линейного предсказания, описывающих речевой сигнал [11] (Маркел Дж.Д..1981кн-Линей_П_Р).

Компиляционные методы синтеза речевого сигнала, в отличие от параметрических, игнорируют физику процесса речеобразования. В них для синтеза речи используются отрезки естественной речевой волны, и из них в дальнейшем собирается (компилируется) речевой сигнал. В качестве отрезков речевой волны могут использоваться самые разные фрагменты:

- микроволны (отрезок, вырезаемый из записей отдельных фонем или аллофонов);
- аллофоны (см. подробнее [раздел 2](#));
- дифоны (всевозможные паросочетания звуков) и др.

При этом используются также комбинированные модели, использующие, например, аллофоны и дифоны.

Описанные выше два класса методов синтеза речевого сигнала обладают своими достоинствами и недостатками. К достоинствам параметрических методов можно отнести следующие:

- простота реализации;
- высокое быстродействие;

- экономичность, т.е. не требуется слишком больших вычислительных ресурсов.

Основным недостатком параметрических методов является то, что при синтезе речи звук оказывается не достаточно естественным, т.е. речь звучит не по-человечески, а как-то «роботно». Это связано с тем, что пока не существует достаточных сведений обо всех акустических особенностях речевого сигнала.

Компиляционные методы имеют следующие достоинства:

- синтезированная речь звучит близко к естественной;
- с помощью компиляционного метода можно «научить» компьютер разговаривать голосом любого человека (например своим голосом) – это качество используется в активно развивающемся в настоящее время направлении клонирования голоса [4] (Лобанов Б.М.2002ст-Комп_К_П_Г).

Недостатки компиляционных методов:

- трудоемкость разработки: для того чтобы создать базу отрезков речевой волны, требуется достаточно долгий кропотливый труд по нарезке этих отрезков из записей различных дикторов;
- для хранения баз голосов требуются довольно большие объемы памяти.

Следует, однако, отметить, что первый из указанных недостатков компиляционных методов с успехом решается путем разработки автоматизированных средств создания баз голосов. Второй недостаток также преодолим, так как во-первых, современные компьютерные мощности уже вполне достаточны для хранения и обработки больших объемов данных, а во-вторых, уже сейчас существуют и продолжают развиваться всевозможные методы сжатия звука.

Рассмотрим основные методы синтеза речевого сигнала более подробно.

3. Геометрическая модель речевого тракта

Одной из первых моделей синтеза речевого сигнала является геометрическая модель речевого тракта. В ее основу положена попытка смоделировать реальный речевой тракт человека (рис. 2.2), выделив в нем основные составляющие и заменив их на соответствующие технические реализации. Воздух, поступающий из легких и проходящий через голосовые связки, образует звук (рис. 3.14). Затем этот звук подвергается дальнейшим изменениям под воздействием органов речеобразования. Таким образом, в местах наибольшего сужения речевого тракта образуется фонема. Для указанных сужений вычисляются площади сечений $S(x)$, которые затем используются в качестве основы для моделирования геометрии речевого тракта.




Рисунок 3.14. Сечения речевого тракта человека

Согласно такому подходу, речевой тракт моделируется в виде набора цилиндрических секций, характерных для того или иного звука (рис. 3.15). Таким образом, геометрия речевого тракта аппроксимируется определенным количеством секций. В среднем их берется по одной секции на один сантиметр речевого тракта. Следует при этом отметить, что у мужчин длина речевого тракта порядка 12 см, а у женщин – около 10 см. Акустическая труба, состоящая из набора секций, возбуждается колебаниями от источника речевого возбуждения, вследствие чего образуются резонансы. Эти процессы моделируются различным образом, с тем чтобы на выходе акустической трубы получился речевой сигнал.




Рисунок 3.15. Моделирование геометрии речевого тракта в виде набора цилиндрических секций

Существует много методов моделирования. Наилучшая цифровая модель, которая сейчас известна и позволяет получить хорошую аппроксимацию синтеза речевого сигнала, это модель, основанная на частичных коэффициентах автокорреляции (PARCOR) [16] (Попов Э.В. ред. 1990 спр-ИскусИ-К1). Синтезатор, построенный на этом методе, имеет вид, представленный на рис. 3.16. На данном рисунке используются следующие обозначения. C_i – секции, моделирующие участки речевого тракта. Параметры этих секций управляются коэффициентами K_i . Голосовой источник возбуждения управляется частотой основного тона F_0 и амплитудой звука A . Источник возбуждения может переключаться на шумовой источник, который также управляется амплитудой (силой) звука $A_{ш}$. Таким образом, включая тот или иной источник возбуждения, а также меняя величины корреляционных коэффициентов K_i , мы изменяем площадь сечения речевого тракта в разных точках и моделируем специфические особенности речевого тракта для всех возможных звуков.




Рисунок 3.16. Схема синтезатора речи, построенного на основе моделирования геометрии речевого тракта

Алгоритмическая схема каждой ячейки C_i может быть представлена в виде схемы, аналогичной представленной на рис. 3.17.




Рисунок 3.17. Схема цилиндрической секции

Таким образом, чтобы промоделировать одну секцию акустической трубы, требуется сделать одно умножение, три сложения и одну задержку.

Такие синтезаторы генерируют достаточно качественную речь. Основная задача – правильно подать на вход коэффициенты K_i и смоделировать источник возбуждения. Из-за того, что текущие размеры речевого тракта определяются трудно, можно только догадываться об их изменении, и до сих пор нет такой действующей модели. Поэтому все-таки лучшие практические результаты показали формантные модели синтеза речевого сигнала (см. [ниже](#)).

4. Формантная модель

Как указано выше, формантная модель является наиболее распространенной и чаще всего используется в реализации систем автоматического синтеза речи. В рамках формантной модели описываются частотные характеристики речи, которые содержат основную информацию о произносимых фонемах. Формантное описание речевого сигнала основывается на результатах акустической теории речеобразования, разработанной Г.Фантом [6] (Фант Г. 1964 кн-Акуст_Т_Р). С акустической точки зрения речевой тракт человека является распределенной акустической системой, конфигурация и размеры которой определяют свойства сигнала, излучаемого этой системой. Главным выводом акустической теории является то, что различия в конфигурациях речевого тракта, обусловленные местом образования фонаем, отражаются на акустическом уровне в положении на частотной оси полюсов акустической системы. Эти полюса проявляются на амплитудно-частотном спектре в виде определенных максимумов, называемых формантами.

Акустические характеристики фонем тесно связаны с артикуляционными особенностями их образования – местом и способом.

Речевой аппарат человека представляется в виде двух параллельных каналов – ротового и носового, образующих единую акустическую систему, возбуждаемую периодическими колебаниями голосовых связок либо турбулентным шумом. Распространение акустических волн в такой системе описывается уравнением Вебстера:

$$\frac{1}{S(x)} \frac{\partial}{\partial x} \left(S(x) \frac{\partial p}{\partial x} \right) = \frac{1}{c^2} \frac{\partial^2 p}{\partial t^2},$$

где $S(x)$ – функция площади сечения тракта вдоль оси x распространения волн; p – давление; c – скорость звука; t – время.

Решение этого уравнения для речевого тракта различных конфигураций, соответствующих различным звукам речи, является основным предметом исследования акустической теории речеобразования. В результате решения получается аналитическое выражение для передаточной функции речевого тракта $H(p)$. В общем случае при достаточно малых потерях (что вполне справедливо для реального речевого тракта):

$$H(p) = \frac{\prod_{m=1}^{\infty} (\tau_m^2 p^2 + 2\xi_m \tau_m p + 1)}{\prod_{n=1}^{\infty} (\tau_n^2 p^2 + 2\xi_n \tau_n p + 1)},$$

где p – комплексная переменная; $\tau_{m,n}$ и $\xi_{m,n}$ – соответственно постоянная времени и коэффициент затухания.

На практике передаточная функция аппроксимируется ограниченным числом формант (до четырех) с помощью последовательно соединенных формантных фильтров.

Определение 3.1.

Под формантой в общем случае понимают полосы передаточной функции речевого тракта, характеризующиеся частотой F_i , амплитудой A_i и полосой пропускания B_i .

На амплитудно-частотном спектре форманты проявляются в виде заметных максимумов (рис. 3.18). Однако не всякий максимум является формантой. Обычно в диапазоне частот первых четырех формант ряд побочных максимумов не является формантами (рис. 3.19).




Рисунок 3.18. Выделение формант в спектре речевого сигнала




Рисунок 3.19. Выделение формант в спектре речевого сигнала для фонемы [а]

Заметим, что основная энергия акустических колебаний речевого сигнала заключена в диапазоне 70 Гц – 7 кГц, причем 95% смысловой информации размещается в более узком диапазоне 200 Гц – 5 кГц. Акустические колебания выше и ниже этих частот несут информацию об эмоциях и личности говорящего, способствуют узнаваемости и несколько повышают разборчивость речи в условиях повышенных шумов.

Анализ вида передаточных функций речевого тракта для различных групп звуков показал, что достаточно полно описать их акустические характеристики можно, используя формантную модель (рис. 3.20).




Рисунок 3.20. Формантная модель акустики речевого тракта

Управляющими параметрами модели являются следующие 10 формантных параметров:

- A_p , A_n – амплитуды голосового возбуждения ротовых и носовых формант;
- A_f – амплитуда шумового возбуждения фрикативных формант;
- A_a – амплитуда аспиративного возбуждения ротовой форманты;
- F_0 – частота основного тона;
- F_1 , F_2 , F_3 – частоты первой, второй и третьей формант;
- F_f – частота фрикативных формант;
- B_f – полоса пропускания фрикативных формант.

Приведенная формантная модель с успехом используется в системах синтеза речи, а ее управляющие параметры являются примером полного набора информативных признаков фонем для систем распознавания речи (см. [подраздел 3.3](#) и [раздел 5](#)).

Различия в способе образования фонем определяются амплитудой голосового возбуждения ротовых формант A_p , носовых формант A_n , амплитудой шумового возбуждения фрикативных формант A_f , амплитудой аспиративного возбуждения ротовых формант A_a , а также частотой основного тона F_0 . Причем очень важной является временная организация этих параметров.

Группа гласных отличается от согласных тем, что для них $A_p = 1$, а $A_f = A_n = A_a = 0$. Кроме того, внутри группы гласных фонем, т.е. по месту образования, гласные отличаются значениями формантных частот F_1 , F_2 и F_3 , причем основную роль играют F_1 и F_2 . На рис. 3.21 приведен пример распределения формантных частот гласных для мужских и женских голосов. Приведенные здесь зависимости значений первой и второй формант для одного голоса образуют так называемые формантные треугольники, в рамках которых распределяются формантные частоты гласных большинства дикторов. Данные на рисунке являются усредненными и могут варьироваться в рамках допустимых диапазонов частот формант для разных голосов.




Рисунок 3.21. Распределение формантных частот гласных для мужских и женских голосов

При внимательном рассмотрении данных формантных треугольников можно сделать определенные выводы о близости (схожести) различных фонем. Например, хорошо видно, что фонемы [ы] и [и] очень незначительно различаются по значению первой форманты. При этом фонемы [у] и [о] близки по значению второй форманты.

Еще один немаловажный вывод заключается в том, что диапазон частот формант женского голоса значительно выше и более разбросан по сравнению с данными для мужского голоса. Этим объясняется то, что большинство систем автоматического синтеза речи «умеют говорить» только мужскими голосами. Кроме того, этот факт привносит дополнительные трудности в решение задачи распознавания речи женского голоса.

Наибольшую роль в разделении согласных по месту образования играет формантная частота F2. Причем вследствие коартикуляции F2 зависит от места образования не только согласного, но и окружающих его гласных (рис. 3.22). Как видно из рисунка, наибольшему коартикуляционному воздействию подвергается группа небных твердых согласных [к], [г], [х], а наименьшему – мягкие согласные.

По способу образования фонемы подразделяются на следующие виды:




Рисунок 3.22. Зависимость частоты второй форманты согласных от частоты гласных в слоге

5. Компиляционные методы синтеза речевого сигнала

Рассмотрим компиляционные методы синтеза речевого сигнала. Как указано выше, эти методы основаны на использовании отрезков естественной речевой волны. Благодаря этому, звук не генерируется, а извлекается из памяти, где хранятся заранее заготовленные отрезки речевой волны. Преимущество таких синтезаторов заключается в том, что они позволяют при определенных условиях приблизить качество синтезированной речи к естественной. Это очень важное преимущество, так как, как бы ни была упрощена модель речевого тракта, все равно мы многого о ней не знаем, особенно того, что касается индивидуальности голоса. Поэтому если потребуется синтезировать свой собственный голос, то лучше использовать компиляционные методы.

Одним из наиболее простых вариантов реализации компиляционного метода синтеза речевого сигнала является аллофонная модель, в которой в качестве отрезков естественной речевой волны используются записи аллофонов. Для реализации систем автоматического синтеза речи на основе указанной модели необходимо выполнить ряд предварительных этапов:

- 1) запись и оцифровка наборов слов или фраз, из которых впоследствии будут вырезаться аллофоны (существуют такие специальные наборы слов для надиктовки, которые рассчитаны на то, что из этих наборов можно будет нарезать необходимое количество аллофонов);
- 2) используя средства редактирования оцифрованного звука, нарезать необходимое количество аллофонов (это делается в основном вручную, на слух; при этом желательно нарезать несколько вариантов одного и того же аллофона, чтобы можно было впоследствии выбрать лучшие по качеству звучания);
- 3) сохранить наборы аллофонов в специальной звуковой базе данных, которая будет использоваться синтезатором

речи. Описанные действия являются достаточно простыми, но проблема заключается в том, какое количество аллофонов требуется подготовить для достаточно хорошего качества синтеза речи. Подсчитаем сначала общее количество аллофонов, которые могут быть в русской речи. При этом требуется учесть типологию аллофонов и их свойства.

Напомним, что аллофоны – это различные варианты звучания фонем в зависимости от их положения в слове. Аллофоны различают двух типов: позиционные и комбинаторные.

Позиционные аллофоны – это варианты фонем в зависимости от их положения по отношению к ударному слогу и в зависимости от типа ударения. Различают сильные и слабые ударения, а также безударные формы. Если ограничиться вариантами "предударная фонема" и "заударная фонема", то получим 6 (3 x 2) вариантов аллофонов одной и той же фонемы в зависимости от типа ударения.

Подсчитаем теперь общее число позиционных аллофонов. Известно, что в русской речи число фонем

$N_{\text{ф}} = 42$.

Каждая фонема может быть представлена в виде позиционного аллофона в 6-ти вариантах, т.е. имеем

$N_{\text{р}} = 6$.

Итак, число позиционных аллофонов

$N_{\text{п.ал.}} = N_{\text{ф}} \times N_{\text{р}} = 42 \times 6 = 252$.

Теперь рассчитаем количество комбинаторных аллофонов. Их число зависит от количества левых и правых контекстов фонем. В общем случае число левых контекстов

$N_{\text{л}} = 42 + 1 = 43$ (т.к. может быть пауза в начале).

Число правых контекстов такое же:

$N_{\text{р}} = N_{\text{л}} = 43$.

Тогда получаем общее число аллофонов русской речи:

$N_{\text{ал.}} = 42 \times 6 \times 43 \times 43 = 466\,000$ – это почти 0,5 млн. аллофонов!

Если мы хотим синтезировать качественную речь, то необходимо набрать базу из такого количества аллофонов. Потом в процессе синтеза речи для каждого слова будут выбираться нужные аллофоны и компилироваться в соответствующий речевой сигнал. Очевидно, что вручную перебрать такое число аллофонов практически нереально. Поэтому разработчики пытаются минимизировать число необходимых аллофонов. Разумеется, при этом стараются не ухудшить качество синтеза.

Для того чтобы минимизировать число аллофонов, необходимо более детально изучить конкретно каждую фонему рассматриваемого языка. На практике оказывается, что далеко не всегда требуется иметь все оттенки звучания для каждой фонемы, так как разные фонемы подвержены разным изменениям: одни больше, другие меньше. Например, одни фонемы могут быть подвержены только позиционным изменениям, а другие – комбинаторным. Причем разные классы фонем меняются в зависимости от правых и левых контекстов. Если это учитывать, то число аллофонов может быть сильно снижено. Исследования показали, что вполне разборчивая и натурально звучащая речь может быть получена с использованием всего

$N_{\text{мин}} = 778$ аллофонов.

Эти аллофоны можно изучить, вырезать из речевого сигнала, составить специальные правила их получения и затем синтезировать речь.

Рассмотрим кратко процесс сокращения количества аллофонов.

Рассмотрим позиционные аллофоны гласных. В русском языке их 12: 6 сильноударных аллофонов и 6 – слабоударных. Но на практике можно ограничиться только сильно ударными аллофонами, так как слабоударные имеют почти те же фонетические качества. Это ограничивает число ударных аллофонов с 12 до 6. Итак, для ударных гласных имеем

[a+], [o+], [y+], [э+], [ы+], [и+] – это ударные аллофоны.

Однако нет необходимости иметь и 6 предударных аллофонов. Оказывается, что в русском языке ударные аллофоны [a+] и [o+] объединяются в предударную [a'], так как безударная гласная «о» переходит в «а». Кроме того, предударного [э'] вообще не существует в русской речи. Такое сокращение числа аллофонов может ухудшить

натуральность звучания, но не намного. Итак, мы имеем 4 предупредных аллофона:

[a'], [y'], [ы'], [и'].

Теперь рассмотрим заударные аллофоны. Исследования показали, что они объединяются всего лишь в 3 аллофона:

- остается аллофон [y];
- аллофоны для фонем [о], [а], [ы] объединяются в аллофон, который обозначается знаком [ь] (произнесите вслух и сравните звучание, например, слов «точно», «красный» и «красная»);
- аллофоны для фонем [э] и [и] объединяются в [ь] (проверьте это, например, на словах «эти» и «красенький»).

Заметим, что в приведенном перечне заударных аллофонов знаки «ь» и «ъ» не являются орфографическими, это аллофонные знаки.

Итого, мы имеем $6 + 4 + 3 = 13$ позиционных аллофонов гласных, вместо 36-ти, которые получались в результате предварительного расчета.

Итак, мы имеем 13 позиционных аллофонов, которые потом модифицируются в комбинаторные, в зависимости от того, какие позиции занимают эти гласные в слове по отношению к другим фонемам, т.е. до и после какого звука они стоят. В качестве левого контекста можно было бы взять все 42 фонемы русского языка. Но при этом, как показано выше, получается около 0,5 млн аллофонов. При анализе буквосочетаний русского языка фонетически оправданными оказываются только некоторые контексты.

Рассмотрим левые контексты для гласных. Они разбиваются на группы по схожести влияния. Итак, в качестве левых контекстов гласных выделяются следующие 10 позиций аллофонов:

- 1) после паузы (гласный стоит в начале синтагмы);
- 2) после твердых зубных и альвеолярных согласных [т], [д], [с], [з], [ц], [ш], а также после гласных [a+], [э+], [a'], [ь];
- 3) после твердых губных согласных [п], [б], [ф], [в] и после огубленных гласных [o+], [y+], [y'], [y];
- 4) после твердых согласных [к], [г], [х];
- 5) после твердого согласного [н];
- 6) после твердого согласного [м] (звуки [н] и [м] существенно влияют на контекст гласного, гласные после носовых согласных становятся нозализованными);
- 7) после твердого звука [р] – требует отдельного аллофона гласного;
- 8) после всех мягких согласных (кроме [м'], [н']) и гласных [и+], [ы+], [и'], [ь'], [ь];
- 9) после согласного [м'];
- 10) после согласного [н'].

Если мы учтем 10 перечисленных левых контекстов, то можно гарантировать, что гласные с левой стороны будут синтезированы правильно, т.е. вполне естественно. Здесь получился почти алгоритм генерации аллофонов.

Рассмотрим типы правых контекстов:

- 1) перед паузой – в конце синтагмы для любого гласного, так как гласный становится слабым, вялым и длинным;
- 2) перед твердыми губными согласными [п], [б], [ф], [в] и гласными [y+], [o+], [y'], [y];
- 3) перед остальными твердыми согласными (кроме [р]) и перед гласными [a+], [э+], [ы+], [a'], [ь], [ь'];
- 4) перед твердым [р];
- 5) перед всеми мягкими согласными и гласными [и+], [ы+], [и'], [ь'], [ь].

Итого, количество комбинаторных аллофонов гласных равно

$13 \cdot 10 \cdot 5 = 650$.

Отметим, что количество аллофонов гласных в русском языке большое, а согласных – не очень, потому что общее число согласных $N_f = 36$. В среднем мы имеем 3-4 аллофона на каждый согласный. Это значит, что согласные гораздо более устойчивы к контекстному влиянию. Даже если взять по одному из 650-ти аллофонов гласных на каждую из 36-ти согласных, качество речи будет уже очень хорошим. Отметим, что аллофоны согласных требуются только для таких слабых звуков, как [й], [р], [л], [в], которые часто рассматриваются как полугласные. Для расчета числа аллофонов согласных такие подробные выкладки делать не будем, но заметим, что правила их генерации известны и используются при синтезе речи.

Вспомним, что основными недостатками компиляционных методов являются:

- 1) потенциально большой объем информации, которую нужно запомнить (для хорошего качества речи требуются тысячи аллофонов);
- 2) очень трудоемкая работа по созданию баз данных элементов речи (это кропотливая, монотонная работа на многие месяцы).

Компромисса между двумя этими недостатками можно достичь, если использовать микроволновой метод синтеза

речевого сигнала [12] (Лобанов Б.М.1991ст-Микро_С_Р_по_Т).

Для того чтобы разобраться в том, что такое микроволны, рассмотрим в качестве примера аллофон гласного. Возьмем следующий комбинаторный аллофон: гласная [а], в левом контексте которой [п], а в правом – [к]. Рассмотрим осциллограмму этого аллофона (рис. 3.23).




Рисунок 3.23. Микроволны на осциллограмме аллофона [а]

Осциллограмма аллофона [а] состоит из отдельных периодов (pitches): от 1 до 5 периодов.

В аллофонном синтезе сохраняется и используется весь сигнал и, кроме того, этих сигналов будет столько, сколько всяких окружений и позиций может вызвать данный сигнал. При микроволновом методе делается попытка синтезировать весь аллофон, исходя только из 3-х микроотрезков исходного аллофона. В качестве сегмента берется период частоты основного тона. Берутся следующие сегменты: начальный сегмент μ_n , срединный сегмент μ_c и конечный μ_k . Эти отрезки берутся естественными, а все остальные микроотрезки генерируются искусственным путем в процессе синтеза речевого сигнала на основе имеющихся сегментов. При этом используются специальные алгоритмы перехода от одного сегмента к другому, которые подробнее будут рассмотрены в [разделе 4](#).

Аналогичным образом используется дифонная модель синтеза речевого сигнала, использующая различные паросочетания звуков речи. Существуют также различные комбинированные модели. Основная цель создания таких моделей – получение высокого качества синтеза речи, приближенной к естественной.

В заключение рассмотрения методов синтеза речевого сигнала следует отметить, что данное рассмотрение далеко не полное, так как в настоящее время существует большое количество рабочих коллективов, стремящихся добиться высоких результатов. Поэтому по-прежнему появляются новые подходы и методы синтеза, некоторые из которых засекречены ввиду их высокой коммерческой востребованности. Возможно, в скором времени появятся и какие-либо новые методы, так как данная область развития вычислительной техники по-прежнему современна и довольно молода.