

Тема 18. МЕТОДЫ РАСПОЗНАВАНИЯ РЕЧИ

Ключевые понятия:

анализатор, анализатор сигналов, анализатор речевых сообщений (=распознаватель), анализатор ограниченного словаря, универсальный анализатор.

На начальных этапах развития проблемы распознавания речи разрабатывались устройства, которые называли анализаторами.

Определение 5.2.

Анализаторы преобразовывают речевые сигналы, поступающие с микрофона, в последовательность цифровых кодов с существенно меньшим информационным потоком (см. раздел 3) и с обязательным сохранением передачи смыслового компонента речи.

Анализаторы подразделяются на два основных класса:

- анализаторы сигналов;
- анализаторы сообщений.

Определение 5.3.

В анализаторах сигналов сокращение информационного потока достигается только за счет учета акустических и статистических характеристик речевого сигнала без обращения к его смысловой функции.

В анализаторах речевых сообщений (распознавателях) осуществляется сжатие информационного потока за счет введения операции распознавания смысловых элементов речи (фразы, слова, морфемы, фонемы). Анализаторы речевых сообщений, в свою очередь, подразделяются на две группы:

- анализаторы ограниченного словаря;
- универсальные анализаторы.

Определение 5.4.

Анализаторы ограниченного словаря ориентированы на распознавание заданного конкретной задачей числа речевых команд (рис. 5.1), т.е. на идентификацию одной из произнесенных речевых команд словаря в виде номера команды.

Распознавание в анализаторах ограниченного словаря осуществляется путем нелинейного во времени сопоставления эталонов команд с произносимой командой и выбора наиболее схожего эталона. В большинстве существующих анализаторов ограниченного словаря формирование эталонов осуществляется в процессе обучения на используемый словарь и голос диктора. Чаще всего процесс обучения состоит в однократном прочтении оператором всего словаря команд. Еще одним ограничением большинства современных анализаторов этого типа является требование изолированного произнесения речевых команд, т.е. с паузами между словами от 0,3 до 1 с. Распознавание слитной речи даже ограниченного словаря – пока нерешенная научная проблема.




Рисунок 5.1. Схема анализатора речевых сообщений ограниченного словаря

Определение 5.5.

Универсальные анализаторы ориентированы на текущее распознавание полного набора смысловых элементов речи (фонем или морфем), из которых может быть составлено и в конечном счете распознано любое слово или слитно

произнесенное речевое сообщение (рис. 5.2). Распознавание осуществляется лингвистическим процессором по правилам, заложенным в базе знаний.




Рисунок 5.2. Схема универсального анализатора речевых сообщений

В настоящее время, как указывалось в [пункте 1.2.2](#), на системы распознавания речи накладываются разного рода ограничения. Это связано с трудностями реализации таких систем. Пока, к сожалению, разработка полноценной универсальной многодикторской системы распознавания речи неограниченного словаря не представляется возможной. В любой существующей на данный момент системе указанного класса имеется свой набор характеристик и ограничений, например, на объем словаря, либо на контингент дикторов, либо на возможности понимания сообщений и т.д. [\[8\]](#) (Рылов А.С.2003кн-Анализ_P).

Методы автоматического распознавания речи

Ключевые понятия:

образ; набор признаков; соотношения, определенные на этих признаках; решающее правило; эталон речи; акустическая модель системы распознавания речи; статистическая модель речевых сигналов; анализ речевого сигнала; вектор признаков; распознающее устройство; классификатор; решающий блок; обучающий блок; распознанный речевой элемент; евклидово расстояние в n -мерном пространстве; расстояние от реализации речевого сигнала до эталона; линейная модель распознавания речи; метод динамического выравнивания по времени; метод скрытых марковских моделей; метод на основе нейросетевых моделей; структурно-экспертный метод; гибридная модель.

Как указывалось выше, задача распознавания речи является очень сложной, так как естественная речь человека является примером нерегулярного биологического явления. Нет двух людей, которые бы говорили абсолютно одинаково. Кроме того, даже один и тот же человек произносит свои высказывания в разные моменты времени по-разному, в зависимости от окружающих его условий и его психофизического состояния. Важную роль здесь играют возраст и пол говорящего. Как указывалось в разделе 2, речь – это не просто набор фонем, а еще и их мелодическая и ритмическая окраска, т.е. просодия. Добавим ко всему этому многообразие передающих сред в «речевой» системе связи (см. [раздел 3](#)). Учет всех этих факторов заставляет разработчиков систем автоматического распознавания речи создавать все новые и новые методы распознавания речи [\[21\]](#) (Ли У. 1983кн-Метод_A_P_P). Рассмотрим в данном разделе основные и наиболее распространенные из них.

1. Распознавание речи как одно из направлений задачи распознавания образов

В общем случае проблема распознавания касается не только речи, а гораздо шире – распознавания различных образов. Это может быть распознавание зрительных образов (например, определение заболеваний по различным симптомам, снимкам и т.д.), распознавание движущихся объектов (например в военных системах наведения), распознавание рукописного или печатного текста (всем известна, например, программа FineReader) и т.п. Задача распознавания образов – очень сложная, так как распознаваемый объект может находиться в самых разных условиях, при этом могут появляться различные искажения и другие препятствия.

Следует, однако, заметить, что название «распознавание образов» - не очень удачное, так как это не совсем точный перевод англоязычного термина «Pattern Recognition». Слово «pattern» на русский язык можно перевести как «образец», «образчик», «шаблон», а также и «образ». Суть задачи распознавания заключается в распознавании данного неизвестного образца, а не образа [\[1\]](#) (Поспелов Д.А.ред.1994слов-Инфор).

Определение 5.6.

Под образом понимается совокупность образцов, класс образцов, в чем-то близких друг другу. Именно из-за близости этих образцов они объединяются в один класс, т.е. в один образ. Например, класс (образ) визуальных изображений буквы А, буквы Б и т.д. или класс звуковых «изображений» буквы А, буквы Б и т.д.

Распознать неизвестный образец (объект, явление, ситуацию, процесс) означает установить, к какому классу (образу) этот объект может быть отнесен. Если, например, данный автомобиль в процессе распознавания отнесен к классу автомобилей ВАЗ, то считается, что он распознан.

В основе всех методов распознавания образов лежат следующие основные положения [1] (Поспелов Д.А.ред.1994слов-Инфор). «Пусть каждый объект распознавания описывается набором признаков $P_1, P_2, \dots, P_k$.

Для каждого объекта (образца) эти признаки принимают вполне определенное числовое или словесное значение. Классы объектов характеризуются некоторыми соотношениями, определенными на этих признаках. Для того чтобы отнести некоторый объект к определенному классу, надо выполнить три шага:

- 1) определить для данного объекта значения признаков;
- 2) проверить на их значениях все соотношения, характеризующие классы объектов;
- 3) определить, к какому классу относится данный объект.

Но эта задача проста только на первый взгляд. Ведь для столь простого ее решения, сводящего задачу распознавания к задаче простой классификации, надо знать три вещи:

- 1) набор классифицирующих признаков $P_1, P_2, \dots, P_k$;
- 2) набор соотношений, определяющих каждый класс объектов;
- 3) решающее правило, с помощью которого происходит выбор класса.

Только знание всех этих элементов сводит задачу распознавания к простой процедуре».

В реальной ситуации, как правило, дело обстоит далеко не так просто. В частности, если говорить о проблеме распознавания речи, то каждый из перечисленных выше элементов представляет собой отдельный большой вопрос. Для определения набора признаков, описывающих речевой сигнал, используются всевозможные методы анализа речи (см. раздел 3). При этом главным критерием качества метода является достаточность признаков для описания смысловой информации, заключенной в речевом сигнале, так как конечной целью распознавания речи является понимание передаваемого с ее помощью сообщения. Существующие методы анализа речи по-прежнему не являются идеальными, так как мы по-прежнему не достаточно знаем о природе речеобразования.

Определением наборов соотношений между признаками отдельных элементов речи занимаются разработчики всевозможных методов распознавания речи. Как правило, по этим признакам определяются различия между отдельными составляющими элементами речевого сигнала (например фонемами).

Решающие правила определяются часто исходя из назначения системы автоматического распознавания речи: будет ли это определением номера отдельной команды, как в случае анализаторов команд (см. подраздел 5.1), либо формированием текста всего сообщения, как в универсальных анализаторах, с последующим анализом смысла сообщения с помощью методов компьютерной лингвистики. Вообще все «задачи распознавания делятся на несколько типов в зависимости от того, какой из элементов задачи является априорно неизвестным. Проще других решаются задачи, когда неизвестным является лишь решающее правило. Необходимость в нем возникает, когда значения классифицирующих признаков удовлетворяют в какой-то мере нескольким классам объектов. Задачи распознавания в этом случае сводятся к задачам, характерным для теории принятия решений.

Когда в качестве неизвестных параметров выступают характеристики классов объектов, то единственный путь решить задачу распознавания – это обратиться к опыту человека или некоторой системы, которая эту задачу умеет решать. При такой постановке возникает обучение распознаванию.

Наконец, случай, когда априорно нет информации о классифицирующих признаках, представляет собой наиболее трудную задачу в теории распознавания. Этот класс задач связан с проведением индуктивных рассуждений и основанным на нем формированием гипотез о возможных классифицирующих признаках.» [1] (Поспелов Д.А.ред.1994слов-Инфор).

В общем случае задача распознавания речевых сигналов может рассматриваться как статистическая задача распознавания образов [22] (Ту Дж..1978кн-Принц Р_О), что позволяет построить оптимальный классификатор на основе критерия максимума апостериорной вероятности. Каждой речевой единице можно сопоставить некоторую модель

$$M_i, i \in \{1, 2, \dots, I\}, \quad (5.1)$$

где I - выбранное число речевых единиц.

Последовательность M_i часто называют эталонами речи. При распознавании неизвестного высказывания (реализации речевого сигнала), представленного последовательностью векторов описания

$$X = \{x_1, x_2, \dots, x_n, \dots, x_N\}, \quad (5.2)$$

ему может быть поставлена в соответствие последовательность моделей M_j , для которой максимальна апостериорная вероятность сопоставления эталона с реализацией

$$P(M_i | X), M_j \in M_i, j = \arg \max_{i \in I} P(M_i | X). \quad (5.3)$$

Для решения задачи (5.3) используется правило Байеса, которое позволяет представить апостериорную вероятность $P(M_i | X)$ как

$$P(M_i | X) = \frac{P(X | M_i)P(M_i)}{P(X)}. \quad (5.4)$$

Расчет апостериорной вероятности разбивается на два этапа:

- 1) расчет функции правдоподобия $P(X | M_i)$ при заданной модели M_i , зависящей от акустических данных;
- 2) оценка априорной вероятности $P(M_i)$.

На этапе распознавания $P(X)$, как правило, является константой, $P(M_i)$ определяется лингвистическими закономерностями языка (Lobanov B.1982art-On_the_Acous), а функция правдоподобия $P(X | M_i)$ определяет акустическую модель системы распознавания речи.

Таким образом, основной задачей любой системы распознавания речи является эффективное и быстрое вычисление акустической функции правдоподобия $P(X | M_i)$ по заданным последовательности акустических векторов $X = \{x_1, x_2, \dots, x_N\}$ описания реализации речевого сигнала и модели M_i описания распознаваемых элементов (эталонов) речи.

Из сказанного следует, что процесс распознавания речи может быть представлен иерархией моделей двух основных его уровней:

- моделями описания собственно речевого сигнала (акустический уровень);
- моделями описания речи и её элементов (лингвистический уровень).

В зависимости от предположений о форме распределения акустических параметров описания речевого сигнала $X = \{x_1, x_2, \dots, x_N\}$ и вводимых ограничений можно построить статистические модели речевых сигналов нескольких типов, наиболее популярными из которых являются модель на основе эталона и скрытая марковская модель.

Отметим также, что распознавание речи, в отличие от распознавания большинства образов, требует отслеживания изменения речи во времени.

Рассмотрим обобщенную структурную схему распознавания речи (рис. 5.3). В соответствии с указанной схемой, в ходе анализа речевого сигнала формируется вектор признаков x_i , которые поступают на распознающее устройство. Это устройство состоит из двух подсистем: классификатора (распознавателя) и обучающего блока. Классификатор сравнивает поступающие признаки с эталонами и передает работу решающему блоку, который вырабатывает решения по выводу распознанных речевых элементов. Эталоны формируются заранее обучающим блоком с участием учителя (человека-диктора). На выходе такой системы получаем распознанные речевые элементы.




Рисунок 5.3. Структурная схема распознавания речи

Рассмотрим отдельные элементы схемы распознавания речи более подробно.

Сравнение текущей реализации речевого сигнала и эталона в основном происходит по следующей схеме. Сначала вычисляется либо расстояние от эталона до реализации в некоторой метрике, либо мера подобия речевых элементов. В результате до каждого эталонного элемента получается свое расстояние или своя мера подобия. Тот элемент, до которого расстояние оказывается наименьшим (или мера подобия наибольшей), считается распознанным. Основные подходы к вычислению расстояния от эталона до реализации рассмотрены ниже. Кроме того, вопросам сравнения реализации речевого сигнала с эталоном будет уделено особое внимание при рассмотрении различных методов распознавания речи.

Обучение происходит следующим образом. Известные реализации речевых элементов задаются учителем и по определенным алгоритмам строятся их эталоны. Проще всего взять в качестве эталонов усредненные реализации речевых сигналов, произнесенных диктором. Как правило, учитель произносит каждое слово (или в некоторых случаях фразу) несколько раз, а система вырабатывает его усредненный эталон. Существуют специальные базы речевых данных: для различных условий распознавания, различных групп дикторов и т.д. Это огромная работа, но на основе ее результатов можно сформировать эталонные речевые элементы. Более подробно механизмы обучения и формирования речевых эталонов будут рассмотрены ниже.

Как сказано выше, основная функция классификатора – это вычисление расстояний между поступившей реализацией и существующими эталонами. Рассмотрим способы вычисления таких расстояний.

Определение 5.7.

Наиболее известны евклидовы расстояния в n -мерном пространстве

$$g(AB) = \sqrt{\sum_{i=1}^n (x_i^{(A)} - x_i^{(B)})^2}$$

где $x_i^{(A)}$, $x_i^{(B)}$ – i -я координата точек А и В.

В случае использования на этапе анализа речевого сигнала многоканального анализатора спектра, то величины спектра по каждому каналу будут соответствовать отдельным координатам. Если, например, взять 12 каналов, то будет 12-мерное пространство (рис. 5.4).




Рисунок 5.4. 12-мерное пространство признаков речевого сигнала

Определение 5.8.

Расстояние от реализации речевого сигнала до эталона определяется по формуле

$$r_{l2} = \sqrt{\sum_{i=1}^n (x_i - x_{in})^2}$$

где x_{in} – координаты эталона.

Заметим, что евклидова метрика известна как метрика Минковского l_2 . Существуют другие метрики: $l_1, l_3, \dots, l_{\infty}$. Метрика l_1 – самая простая, в ней расстояние равно сумме модулей расстояний:

$$r_{l1} = \sum_{i=1}^n |x_i - x_{in}|$$

Часто матрица пространства признаков нормируется нормирующим коэффициентом $1/n$.

Как указывалось выше, кроме спектрального представления речевого сигнала существует также представление на формантной плоскости (рис. 5.5).




Рисунок 5.5. Пространство признаков фонем русских гласных на формантной плоскости

Для данной формантной плоскости можно построить матрицу взаимных расстояний в метрике l_1 (табл. 5.1).

Таблица 5.1. Матрица взаимных расстояний гласных фонем русской речи в метрике l_1

	У	О	А	Э	Ы	И
У	0	0,75	1,5	1,25	0,5	1
О	0,75	0	0,75	0,5	0,75	1,25
А	1,5	0,75	0	0,75	1	1,5
Э	1,25	0,5	0,75	0	0,75	0,75
Ы	0,5	0,75	1	0,75	0	0,5
И	1	1,25	1,5	0,75	0,5	0

Для двоичных признаков существует число несовпадений. Например, произнесён звук, попавший на формантной плоскости в точку X (см. рис. 5.4). Рассчитаем расстояния до всех эталонов (табл. 5.2).

Таблица 5.2. Расчет расстояний от распознаваемой фонемы X до гласных фонем русской речи

	О	Э	Ы	А	У	И
X	0,25	0,25	0,5	0,5	1	1

Исходя из полученных расстояний, можно сделать вывод, что вероятнее всего был произнесен звук [О] или [Э], не исключено, что [Ы] или [А], но точно не [И] и не [У]. Если распознаваемых элементов только два, их удобно рассматривать в признаковом пространстве, разбиваемом на два полупространства. Когда эталонов много, их областям обычно соответствуют эллипсы. Задача распознавания в этом случае заключается в формировании разделяющих гиперплоскостей (рис. 5.6).




Рисунок 5.6. Разделяющие гиперплоскости

2.Классификация методов распознавания речи

Выше были рассмотрены универсальные элементы теории распознавания. В случае распознавания речи самое сложное заключается в осуществлении процедуры сравнения двух речевых элементов, которые характеризуются еще и протяженностью во времени. В настоящее время существует достаточно много таких процедур и методов (рис. 5.7).



Рисунок 5.7. Методы распознавания речи

Линейные модели распознавания речи появились раньше всего..

Определение 5.9.

В линейных моделях распознавания речи предполагается, что для сравнения реализации речевого сигнала с эталоном достаточно простого масштабирования во времени.

Однако в речи существенны нелинейные искажения времени. Иначе говоря, линейная модель предполагала сравнение реализации с эталоном по линейному закону (рис. 5.8), тогда как изменения в реализации подвергаются нелинейным искажениям. Очевидно, что такая модель работала неудовлетворительно.




Рисунок 5.8. Схема работы линейной модели распознавания речи

Позже, учитывая недостатки линейной модели, появился метод динамического выравнивания по времени.

Определение 5.10.

В методе динамического выравнивания по времени траектория сравнения реализации с эталоном могла отличаться от линейной. Данный метод, называемый также методом динамического программирования (ДП–методом) [9] (Винцюк Т.К.1987кн-Анализ_Р_и_И), позволил существенно улучшить результаты распознавания. Предпосылкой создания ДП-метода было стремление нормализовать временные деформации произносимой команды, возникающие вследствие произвольных изменений темпа и манеры произнесения.

Но некоторые недостатки у данного метода все-таки оставались. В частности, для хорошего распознавания требовались большие вычислительные ресурсы и большие объемы памяти для хранения эталонов (для каждого диктора – свой набор эталонов). Более подробно метод динамического программирования будет рассмотрен ниже.

Определение 5.11.

В методе скрытых марковских моделей эталон представляется не в виде цепочки отсчетов сигнала, а в виде вероятностей переходов от одних состояний к другим. Подробнее этот метод будет рассмотрен позже.

Главным преимуществом указанных выше методов является то, что они дают надежные результаты распознавания при небольших затратах. Основным их недостатком является наличие слишком сложных процедур обучения. В связи с этим появился следующий активно развивающийся метод – на основе нейросетевых моделей (neuronets models). Такие модели позволяют формализовать механизм обучения более эффективно.

Определение 5.12.

Еще один класс методов – на основе экспертных знаний (knowledge approach) – так называемые структурно-экспертные методы. Этот подход предполагает использование не только формализуемых математических моделей, но и баз знаний, формализующих некоторые речевые и языковые модели. Этот метод в настоящее время особенно перспективен для речевого распознавания, у него большое будущее.

Остальные методы в чистом виде себя уже исчерпали. Поэтому часто на практике разработчики прибегают к использованию нескольких методов в рамках одной системы. В таких гибридных моделях используются все положительные качества новейших групп методов.